



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Disciplina: Estatística Aplicada – Período: 2026.1

Professores: Profa. Dra. Amanda Gomes; Prof. Dr. Jerfson Bruno; Prof. Dr. Gilberto Matos

Modelagem da Relação entre Características Morfológicas de Pinguins

João Vítor Neves, Darlan Almeida, Emerson Sulpino

Departamento de Ciência da Computação - UFCG

Resumo Este trabalho aplica a metodologia de regressão linear múltipla (MRLM) ao conjunto de dados *Palmer Penguins*, proveniente do programa de Pesquisa Ecológica de Longo Prazo (LTER) na Antártica Ocidental, com o objetivo de modelar o comprimento da nadadeira de pinguins das espécies *Adelie*, *Chinstrap* e *Gentoo* a partir de variáveis morfológicas e categóricas. Realizou-se uma análise exploratória das distribuições, correlações e dados ausentes, seguida da combinação de diferentes subconjuntos de preditores avaliados por validação cruzada K-fold. O subconjunto com o menor RMSE médio (espécie, comprimento e profundidade do bico e massa corporal) apresentou colinearidade severa ($VIF > 10$) associada à espécie *Gentoo*, o que motivou seu descarte em favor de um modelo alternativo, estatisticamente equivalente em desempenho preditivo (teste t pareado com correção de Nadeau-Bengio, $p = 0,14$) e livre de multicolinearidade: o modelo composto exclusivamente pelas variáveis qualitativas espécie, ilha e sexo. Esse modelo, adotado como versão final, apresentou R^2 ajustado de 0,835, resíduos aproximadamente normais e desempenho preditivo estatisticamente indistinguível do modelo mais complexo, evidenciando que o equilíbrio entre desempenho preditivo, parcimônia e ausência de colinearidade é o critério mais adequado para a seleção final, e não a validação cruzada isoladamente.

Palavras-Chave: regressão linear múltipla, multicolinearidade, seleção de modelos, palmer penguins, análise exploratória, características morfométricas

Contents

Modelagem da Relação entre Características Morfológicas de Pinguins	1
1. Introdução	3
Objetivos da análise	3
Variável resposta:	3
2. Descrição da base	3
3. Metodologia	4
3.1 Exploração dos dados	4
3.2 Combinação de variáveis avaliadas por validação cruzada K-fold	4
3.3 Análise dos resultados da validação cruzada	4
3.4 Seleção do modelo	4
3.5 Diagnóstico dos pressupostos dos resíduos, intervalos de confiança e de predição	4
4. Análise Exploratória	5
4.1 Distribuição das variáveis	5
4.2 Tratamento de dados	6
4.3 Avaliação de correlação entre variáveis	7
5. Seleção de Variáveis e Regressão dos modelos	8
5.1 Combinação de Variáveis e Validação Cruzada	8
5.2 Diagnóstico de Multicolinearidade do Candidato de Menor RMSE	9
5.3 Seleção do Modelo Final	9
5.4 Modelo Final: Estimativas dos Coeficientes	10
6. Análise de Resíduos	11
7. Previsão e Incerteza	12
8. Conclusões	13
Referências	14

1. Introdução

Este trabalho utiliza o conjunto de dados *Palmer Penguins*, coletado pelo programa de Pesquisa Ecológica de Longo Prazo (LTER) entre 2007 e 2009, para investigar quais características morfológicas e categóricas explicam o comprimento da nadadeira dos indivíduos amostrados. Diferentemente de uma descrição puramente correlacional, buscamos um modelo de regressão linear múltipla (MRLM) que permita interpretar efeitos parciais — isto é, o efeito de cada variável mantendo as demais constantes —, avaliar a adequação de suas suposições e quantificar a incerteza tanto para o valor médio esperado da resposta quanto para novas observações individuais. A validação cruzada K-fold foi empregada como ferramenta de comparação de desempenho preditivo entre subconjuntos de variáveis candidatas, e não como critério único e automático de seleção do modelo final

Objetivos da análise

- Caracterizar exploratoriamente as variáveis morfológicas e categóricas disponíveis;
- Ajustar um modelo inicial com todas as variáveis explicativas e avaliar multicolinearidade;
- A validação cruzada K-fold foi empregada como ferramenta de comparação de desempenho preditivo entre subconjuntos de variáveis candidatas, e não como critério único e automático de seleção do modelo final;
- Selecionar, entre modelos candidatos, aquele com melhor equilíbrio entre desempenho preditivo, parcimônia e colinearidade controlada dentro de limites aceitáveis;
- Verificar as suposições do MRLM por meio de diagnóstico de resíduos;
- Construir intervalos de confiança e de predição para cenários específicos, com interpretação prática.

Variável resposta:

Usaremos `flipper_length_mm` — o comprimento da nadadeira, em milímetros — como resposta. Queremos investigar e prever essa medida partir das demais informações disponíveis sobre o pinguim: espécie, ilha, medidas do bico, massa corporal, sexo e ano de coleta.

Pergunta formulada:

Entre pinguins semelhantes nas demais características consideradas, como o comprimento esperado da nadadeira varia com cada preditor, e quão bem o modelo prevê novos pinguins?

2. Descrição da base

A base de dados Palmer Penguins possui $n = 344$ espécimes registrados, coletados no arquipélago Palmer, na Antártica Ocidental, entre 2007 e 2009. A unidade de análise é o indivíduo, e a base reúne 8 variáveis morfológicas, categóricas e temporais, descritas na Tabela 1.

Table 1: Dicionário de variáveis

Variável	Tipo	Papel	Definição	Unidade
<code>species</code>	Categórica	Preditor	Espécie do pinguim (Adelie, Chinstrap, Gentoo)	-
<code>island</code>	Categórica	Preditor	Ilha de observação (Dream, Torgersen, Biscoe)	-
<code>bill_length_mm</code>	Numérica	Preditor	Comprimento do bico	milímetros
<code>bill_depth_mm</code>	Numérica	Preditor	Profundidade do bico	milímetros
<code>flipper_length_mm</code>	Numérica	Resposta	Comprimento da nadadeira	milímetros
<code>body_mass_g</code>	Numérica	Preditor	Massa corporal	gramas
<code>sex</code>	Categórica	Preditor	Sexo do pinguim (male, female)	-
<code>year</code>	Inteira	Descartada	Ano em que a observação foi registrada	-

A qualidade da base foi avaliada antes de qualquer modelagem: 11 registros (3,2%) não possuem sexo identificado, e 2 registros adicionais não possuem nenhuma das medidas morfológicas nem sexo — permanecendo disponíveis apenas espécie, ilha e ano. O tratamento dado a esses casos, assim como a decisão sobre a variável *year*, é discutido em detalhe na Seção 4.2, dentro da análise exploratória.

3. Metodologia

A análise foi estruturada em cinco etapas sequenciais, detalhadas nas Seções 4 a 7 e resumidas a seguir.

3.1 Exploração dos dados

Exame das distribuições univariadas e bivariadas das variáveis morfológicas e categóricas, tratamento dos dados ausentes (variáveis *sex* e *year*) e avaliação da correlação entre os preditores contínuos e a resposta (Seção 4).

3.2 Combinação de variáveis avaliadas por validação cruzada K-fold

A partir do modelo completo (Seção 5), todos os subconjuntos possíveis de grupos de preditores (espécie, ilha, sexo, comprimento do bico, profundidade do bico, massa corporal) foram avaliados por validação cruzada K-fold ($k = 5$), utilizando o RMSE médio como métrica principal de desempenho preditivo (Seção 5.1).

3.3 Análise dos resultados da validação cruzada

Os subconjuntos com melhor desempenho foram comparados entre si por meio do teste *t* pareado com correção de variância de Nadeau-Bengio, que ajusta a variância estimada para compensar a dependência entre as dobras de treino e teste, controlando a inflação de falsos positivos característica da validação cruzada *k*-fold (Nadeau & Bengio, 2003) (Seção 5.1).

3.4 Seleção do modelo

O subconjunto de menor RMSE médio foi diagnosticado quanto à multicolinearidade pelo Fator de Inflação da Variância (VIF), definido como $VIF_j = 1/(1-R^2)$, em que R^2 é o coeficiente de determinação da regressão de X_j sobre as demais explicativas; valores de $VIF > 10$ foram tratados como indicativo de multicolinearidade severa. Constatada colinearidade severa nesse subconjunto (Seção 5.2), a seleção final priorizou, entre os candidatos estatisticamente equivalentes em desempenho, o modelo livre desse problema e com coeficientes mais diretamente interpretáveis — e não apenas o de menor RMSE (Seção 5.3).

3.5 Diagnóstico dos pressupostos dos resíduos, intervalos de confiança e de predição

A validação do modelo final ancorou-se na verificação gráfica e formal dos pressupostos clássicos dos resíduos (Seção 6): - Linearidade e Homocedasticidade: diagrama de resíduos versus valores ajustados e Teste de Breusch-Pagan (H_0 : variância constante); - Normalidade dos Erros: gráfico Q-Q Plot e teste formal de Jarque-Bera (H_0 : distribuição normal dos erros); - Independência dos Erros: Teste de Durbin-Watson (H_0 : ausência de autocorrelação nos resíduos). (TALVEZ TROCAR POR OUTRO TESTE)

Por fim, construíram-se intervalos de confiança (IC) para a média e intervalos de predição (IP) para observações individuais em cenários hipotéticos representativos de cada espécie (Seção 7).

4. Análise Exploratória

4.1 Distribuição das variáveis




Figure 1: Distribuição de variáveis qualitativas

A espécie *Adelie* é a mais representativa da amostra (152 indivíduos; 44,2%), seguida por *Gentoo* (124; 36,0%) e *Chinstrap* (68; 19,8%). Geograficamente, *Biscoe* concentra quase metade dos registros (168; 48,8%), seguida por *Dream* (124; 36,0%) e *Torgersen* (52; 15,1%). O sexo está quase perfeitamente balanceado entre os indivíduos identificados (165 fêmeas, 168 machos), restando 11 sem identificação.




Figure 2: Distribuição de variáveis quantitativas

Os diagramas de caixa, da Figura 2, confirmam a consistência das distribuições morfométricas na amostra. Nota-se a semelhante distribuição, entre as espécies *Adelie* e *Chinstrap*, para características como massa corporal, tamanho da nadadeira e profundidade do bico, fato que pode ser explicado pela **convergência ecomorfológica e sobreposição parcial de nicho trófico entre ambas as espécies**, que compartilham hábitos de forrageamento de menor profundidade em relação aos *Gentoo*. Por outro lado, a espécie *Gentoo* se distingue acentuadamente por apresentar maior massa corporal e nadadeiras significativamente mais

longas (gigantismo relativo dentro do gênero), porém acompanhadas por bicos proporcionalmente mais rasos (*bill_depth*).

4.2 Tratamento de dados

4.2.1 Variável Sexo A análise inicial da variável sexo revelou a presença de 11 registros ausentes (NaN), perceptível na Figura 1, o que corresponde a aproximadamente 3,2% da base total. Como proporções de dados faltantes inferiores a 5% são consideradas irrisórias na literatura de análise de dados, acarretando perda negligenciável de poder estatístico, optou-se pela exclusão direta desses indivíduos do conjunto de dados.

Considerando as seguintes hipóteses:

$$H_0 : \mu_{\text{male}} = \mu_{\text{female}} \quad H_1 : \mu_{\text{male}} \neq \mu_{\text{female}}$$

A aplicação do teste *t* de Student rejeitou a hipótese nula de igualdade entre as médias ($t = 4,801$; $p < 0,001$), fornecendo fortes evidências de associação entre o sexo e o tamanho da nadadeira. Complementarmente, o cálculo do Coeficiente de Cohen, que resultou em ($d = 0,526$), classificado como um efeito de magnitude moderada segundo os limiares convencionais (pequeno 0,2; moderado 0,5; grande 0,8) propostos por Cohen (1988). Dessa forma, entende-se que a variável possui alta relevância explicativa e tamanho de efeito considerável, cuja exclusão deve se restringir estritamente às linhas com informações ausentes, enquanto a variável sexo justifica plenamente sua inclusão na formulação do modelo completo inicial.




Figure 3: Distribuição do tamanho da nadadeira por Ano

4.2.2 Variável Ano Diferentemente do que uma inspeção apenas visual da Figura 3 poderia sugerir, o ano de coleta não é estatisticamente irrelevante para a resposta: uma ANOVA de um fator (*flipper_length_mm* ~ *year*) rejeita a hipótese de médias iguais entre os três anos ($F = 5,41$; $p = 0,005$), e o efeito permanece altamente significativo mesmo controlando por espécie, ilha e sexo (teste F para a inclusão de year no modelo qualitativo: $F = 25,68$; $p < 0,001$), elevando o R^2 ajustado de 0,835 para 0,857. Ainda assim, year foi descartada da modelagem, por duas razões que se complementam. Primeiro, razão substantiva: a distribuição de espécies não é idêntica entre os anos (*Adelie*: 44/50/52; *Chinstrap*: 26/18/24; *Gentoo*: 33/45/41, em 2007/2008/2009), de modo que parte da associação entre *year* e a resposta é herdada da composição amostral, e não de uma mudança biológica real ano a ano. Segundo, e mais decisivo: razão de generalização. Em um cenário real de aplicação do modelo, os anos presentes na base de treinamento

(2007/2009) não estarão mais disponíveis para observações futuras — um pinguim medido em 2026 teria um valor de *year* fora do domínio observado, exigindo extrapolação categórica sem sustentação nos dados. Uma variável de calendário específica ao período de coleta não generaliza para novas coletas, ao contrário de espécie, ilha, sexo e medidas morfológicas, que são atributos válidos para qualquer pinguim amostrado no futuro. Por esse motivo, apesar de sua significância estatística nesta amostra, *year* foi excluída de todos os modelos candidatos.





Figure 4: Mapa de calor entre variáveis



Pela separação de espécies, fica clara a forte e positiva correlação entre a massa corporal do pinguim e o tamanho de sua nadadeira, isso para todas as três espécies avaliadas. Essa constatação é central para a discussão de multicolinearidade na Seção 5.2: variáveis contínuas fortemente associadas à espécie tendem a ser redundantes com ela em um mesmo modelo. Ademais, vê-se uma extensão da similaridade antes comprovada nos diagramas de caixa que as espécies *Adelie* e *Chinstrap* compartilham de características intrínsecas para tamanho da nadadeira e profundidade do bico

5. Seleção de Variáveis e Regressão dos modelos

A partir do modelo inicial apresentado na Seção 2.1, com todas as variáveis explicativas disponíveis (exceto os espécimes sem sexo identificado, tratados na Seção 4.2.1), construímos o Modelo Completo como ponto de partida para a seleção de variáveis:

$$y_i = \beta_0 + \beta_1 \text{tamBico}_i + \beta_2 \text{profundBico}_i + \beta_3 \text{massaCorp}_i + \beta_4 \text{chinstrap}_i \\ + \beta_5 \text{gentoo}_i + \beta_6 \text{dream}_i + \beta_7 \text{torgersen}_i + \beta_8 \text{male}_i + \varepsilon_i.$$

em que *Chinstrap* e *Gentoo* são indicadoras da espécie (*Adelie* como referência), *Dream* e *Torgersen* são indicadoras da ilha (*Biscoe* como referência) e *male* é indicadora do sexo (*female* como referência). Antes de comparar subconjuntos de preditores por validação cruzada (Seção 5.1), avaliamos primeiro se a variável espécie — apontada na análise exploratória (Seções 4.1 e 4.3) como fortemente associada às demais medidas morfológicas — de fato acrescenta poder explicativo, comparando por ANOVA o Modelo Completo contra sua versão restrita sem espécie.

Table 2: Análise de Variância comparando o modelo restrito e o completo.

Modelo	GL Res.	RSS	GL	Soma dos Quadrados	Estat. F	Valor-p
Modelo Sem Espécie	326	10820.65	NA	NA	NA	NA
Modelo Com Espécie	324	8768.47	2	2052.18	37.91	< 0,001

Com $F = 37,91$ e $p < 0,001$, rejeita-se a hipótese nula de que os dois modelos possuem a mesma capacidade explicativa: a espécie contribui de forma estatisticamente significativa para a predição do comprimento da nadadeira. Essa constância motivou sua inclusão em todos os subconjuntos candidatos avaliados a seguir.

5.1 Combinação de Variáveis e Validação Cruzada

Realizou-se uma busca exaustiva por combinações de grupos de variáveis (espécie, ilha, sexo, comprimento e profundidade do bico, massa corporal), avaliadas por validação cruzada K-Fold ($k = 5$), utilizando o RMSE médio como métrica principal. Para comparar os candidatos mais competitivos, aplicou-se o teste t pareado com a correção de variância de Nadeau-Bengio (*Nadeau & Bengio, 2003*):

Table 3: Comparativo de Desempenho Preditivo entre Subconjuntos de Variáveis

Modelo	Variáveis Preditores	RMSE Médio (K-Fold)	R ² Ajustado
Candidato Multicolinear	Espécie, Bico (Compr. e Prof.), Massa	5.29 mm	0.861
Modelo A (Qualitativo)	Espécie, Ilha, Sexo	5.77 mm	0.835
Modelo B (Quantitativo)	Bico (Compr. e Prof.), Massa	5.86 mm	0.830

5.2 Diagnóstico de Multicolinearidade do Candidato de Menor RMSE

O subconjunto de menor RMSE médio (espécie, comprimento e profundidade do bico e massa corporal) foi diagnosticado quanto à multicolinearidade pelo VIF antes de ser considerado modelo final.

Table 4: Fator de Inflação da Variância (VIF) do candidato de menor RMSE.

Variável	VIF
species_Chinstrap	4.115
species_Gentoo	14.654
bill_length_mm	5.534
bill_depth_mm	5.449
body_mass_g	5.894

A indicadora referente à espécie *Gentoo* apresenta $VIF = 14,65$, ultrapassando o limiar de severidade ($VIF > 10$) definido na Seção 3.4. Esse resultado decorre da forte associação entre a espécie *Gentoo* e as variáveis *body_mass_g* e *bill_depth_mm*: indivíduos dessa espécie apresentam massa corporal média de 5.092g — cerca de 37% acima de *Adelie* (3.706g) e *Chinstrap* (3.733g) — e profundidade de bico média de 15,0mm, sensivelmente menor que os 18,3–18,4mm das outras duas espécies. Em outras palavras, saber que um pinguim é *Gentoo* já entrega grande parte da informação que *body_mass_g* e *bill_depth_mm* também carregam: é essa sobreposição de informação que o VIF detecta matematicamente.

Colinearidade severa não invalida o poder preditivo agregado do modelo, mas compromete a interpretação isolada de cada coeficiente — em particular, o efeito estimado da espécie *Gentoo*, misturado ao efeito da massa e da profundidade do bico, deixa de ser confiável para leitura individual. Diante disso, esse candidato não foi mantido como modelo final.

5.3 Seleção do Modelo Final

A decisão entre os candidatos não se apoiou apenas no RMSE médio, mas no conjunto de evidências reunidas nas Seções 5.1 e 5.2. Os três testes pareados relevantes indicam:

- Candidato Multicolinear vs. Modelo Qualitativo: sem diferença significativa de desempenho ($p = 0,14$);
- Modelo Qualitativo vs. Modelo Quantitativo: sem diferença significativa de desempenho ($p = 0,79$);
- Candidato Multicolinear vs. Modelo Quantitativo: diferença estatisticamente significativa ($p = 0,02$), favorecendo o candidato multicolinear.

Como o Candidato Multicolinear não supera o Modelo A (Qualitativo) de forma estatisticamente significativa, e apresenta colinearidade severa que o Modelo A não apresenta (VIF máximo de 3,17, ante 14,65), optou-se por descartar o candidato de menor RMSE bruto e adotar o Modelo Qualitativo — composto por espécie, ilha e sexo — como modelo final. Essa escolha equilibra três critérios: desempenho preditivo estatisticamente equivalente ao melhor candidato, ausência de multicolinearidade relevante entre os preditores, e maior interpretabilidade dos coeficientes, já que nenhuma variável contínua se sobrepõe informacionalmente à espécie.

O Modelo Quantitativo, embora também livre de colinearidade, foi descartado por apresentar desempenho preditivo estatisticamente inferior ao candidato de menor RMSE ($p = 0,02$) e por prescindir da variável espécie, cuja contribuição individual havia sido comprovada pela ANOVA da Tabela 2.

Table 6: Medidas globais de ajuste do modelo vencedor.

Medida	Valor
R ² ajustado	0.835
AIC	2111.440
BIC	2138.090

5.4 Modelo Final: Estimativas dos Coeficientes

A Tabela 5 apresenta as estimativas do modelo final, ajustado com todas as 333 observações após a limpeza (Seção 4.2):

$$\text{flipper length mm} = \beta_0 + \beta_1 \cdot \text{chinstrap} + \beta_2 \cdot \text{gentoo} + \beta_3 \cdot \text{dream} + \beta_4 \cdot \text{torgersen} + \beta_5 \cdot \text{male} + \varepsilon$$

Table 5: Estimativas dos coeficientes do modelo final (Modelo A).

Variável	Estimativa	Erro Padrão	Estatística t	Valor-p
Intercepto (Adelie, Biscoe, fêmea)	185.3651	0.9134	202.9368	< 0,001
Espécie: Chinstrap	5.9586	1.0327	5.7701	< 0,001
Espécie: Gentoo	28.3534	1.0047	28.2203	< 0,001
Ilha: Dream	1.0694	1.1517	0.9286	0,353804
Ilha: Torgersen	2.8094	1.1945	2.3520	0,019267
Sexo: Macho	6.8606	0.6242	10.9912	< 0,001

O modelo final apresenta R^2 ajustado de 0,835, indicando que aproximadamente 83,5% da variabilidade observada no comprimento da nadadeira é explicada por espécie, ilha e sexo. Mantidas as demais variáveis constantes, ser *Gentoo* está associado a uma nadadeira, em média, 28,4mm mais longa que *Adelie*; ser *Chinstrap*, a uma nadadeira 6,0mm mais longa; e ser macho, a uma nadadeira 6,9mm mais longa que fêmea. O efeito da ilha é mais discreto: viver em *Torgersen* está associado a uma nadadeira 2,8mm mais longa que em *Biscoe* ($p = 0,019$), enquanto o efeito de *Dream* não é estatisticamente distinguível de *Biscoe* ($p = 0,354$) — a variável foi mantida por seu efeito de conjunto (grupo island) e porque sua remoção isolada não é o objetivo desta seleção, feita por grupos de variáveis e não por preditor individual.

Table 7: Fator de Inflação da Variância (VIF) do modelo final (Modelo A).

Variável	VIF
Espécie: Chinstrap	1.780
Espécie: Gentoo	2.381
Ilha: Dream	3.173
Ilha: Torgersen	1.776
Sexo: Macho	1.000

Todos os VIFs do modelo final estão bem abaixo do limiar de severidade ($\text{VIF} > 10$), com máximo de 3,17 para *island_Dream* — confirmando a ausência de multicolinearidade relevante e reforçando a leitura individual dos coeficientes apresentados na Tabela 5.

6. Análise de Resíduos




Figure 5: Gráficos de diagnóstico de resíduos

Table 8: Testes Formais de Diagnóstico dos Resíduos do Modelo Vencedor.

Teste Diagnóstico	Premissa Avaliada	Estatística	Valor-p
Breusch-Pagan	Homocedasticidade	13.0428	0,022981
Jarque-Bera	Normalidade	0.0506	0,975032
Durbin-Watson	Independência (Autocorr.)	1.7811	0,014784

A Figura 5 ilustra o diagnóstico de resíduos e a tabela 8 apresenta os resultados dos testes estatísticos formais aplicados aos resíduos do modelo selecionado. A análise indica que, ao nível de 5% de significância, houve rejeição das hipóteses nulas para as três premissas clássicas do modelo de Mínimos Quadrados Ordinários.

O diagnóstico dos resíduos do modelo final é sensivelmente melhor que o do candidato descartado na Seção 5.2. O teste de Jarque-Bera não rejeita a normalidade dos erros ($p = 0,975$), resultado consideravelmente mais favorável do que o observado para o candidato multicolinear ($p = 0,0285$ no modelo original), o que é coerente com a substituição de preditores contínuos correlacionados por indicadoras categóricas bem separadas entre

grupos. O teste de Durbin-Watson (1,78) situa-se próximo de 2, não indicando autocorrelação relevante nos resíduos. Persiste, porém, heterocedasticidade estatisticamente detectável pelo teste de Breusch-Pagan ($p = 0,023$): a variância dos resíduos não é totalmente constante ao longo dos valores ajustados. Como no candidato original, esse padrão é compatível com o contexto biológico — é esperado que espécimes de maior porte apresentem variabilidade natural superior à de espécimes menores — mas, diferentemente do observado antes, o p-valor é menos extremo, sugerindo heterocedasticidade mais moderada.




Figure 6: Distribuição de resíduos por espécie

Na Figura 6 nota-se não apenas a assimetria de diferentes espécimes representados no gráfico, como a tendência da espécie maior *Gentoo* ser menos dispersa que as demais espécies *Adelie* e *Chinstrap*. A separação dos valores ajustados por espécie confirma que o modelo final discrimina corretamente os três grupos (*Adelie* e *Chinstrap* concentrados nos valores preditos mais baixos, *Gentoo* isolado nos valores mais altos), sem sobreposição relevante entre as nuvens de resíduos das diferentes espécies.

7. Previsão e Incerteza

Com o modelo vencedor, foram construídos três cenários representativos, correspondentes a um pinguim típico de cada espécie da base de dados. A Tabela 9 descreve as características morfológicas adotadas em cada cenário, e a Tabela 10 apresenta as estimativas do comprimento da nadadeira juntamente com seus respectivos intervalos de confiança (IC) e de predição (IP).

Table 9: Cenários hipotéticos utilizados na previsão.

Cenário	Espécie	Ilha	Sexo
Pinguim A	Adelie	Dream	female
Pinguim B	Chinstrap	Dream	female
Pinguim C	Gentoo	Biscoe	male

Table 10: Intervalos de confiança e de predição para o comprimento da nadadeira.

Cenário	Intervalo	Estimativa	Inferior	Superior
Pinguim A	IC 95% da média	186.43	184.80	188.07
Pinguim B	IC 95% da média	192.39	190.90	193.88
Pinguim C	IC 95% da média	220.58	219.39	221.77
Pinguim A	IP 95% individual	186.43	175.11	197.76
Pinguim B	IP 95% individual	192.39	181.09	203.69
Pinguim C	IP 95% individual	220.58	209.31	231.84

O intervalo de confiança (IC) captura a incerteza sobre o comprimento médio esperado de todos os pinguins com aquele conjunto de preditores; o intervalo de predição (IP) captura a incerteza para um único pinguim novo, incorporando também a variação residual do modelo — por isso é sempre mais amplo, e é o apropriado para estimar um indivíduo específico. Essa diferença aparece claramente nos três cenários: o IP tem entre 6 e 10 vezes a amplitude do IC correspondente (por exemplo, no Pinguim A, 22,65mm de amplitude contra apenas 3,27mm), refletindo que o IC responde apenas pela incerteza da média, enquanto o IP soma a ela a variabilidade individual não explicada pelo modelo. Os três cenários não se sobrepõem em nenhum dos dois tipos de intervalo, reforçando numericamente o que já havia sido observado nos boxplots da Seção 4.1 e no gráfico de resíduos por espécie da Seção 6: a espécie mantém forte poder discriminativo sobre o comprimento da nadadeira, mesmo em um modelo composto inteiramente por variáveis categóricas.

8. Conclusões

As variáveis morfológicas dos pinguins do arquipélago *Palmer* mostram-se fortemente associadas entre si e nitidamente agrupadas por espécie, refletindo distinções anatômicas claras de massa e estrutura de bico. A avaliação por validação cruzada K-fold indicou que o subconjunto de menor RMSE médio (espécie, medidas do bico e massa corporal) era, ao mesmo tempo, o de maior colinearidade ($VIF = 14,65$ para *Gentoo*) — evidência de que a menor métrica de erro, isoladamente, não é suficiente para escolher um modelo final.

Diante da equivalência estatística de desempenho entre esse candidato e um modelo composto apenas por espécie, ilha e sexo (*teste t pareado com correção de Nadeau-Bengio*, $p = 0,14$), e da ausência de multicolinearidade relevante nesse segundo modelo (VIF máximo de 3,17), optou-se por adotá-lo como modelo final. Esse modelo, inteiramente qualitativo, preservou um bom poder explicativo (R^2 ajustado = 0,835) e apresentou diagnóstico de resíduos mais favorável que o candidato descartado, com normalidade dos erros não rejeitada pelo teste de Jarque-Bera ($p = 0,975$) e independência confirmada pelo teste de Durbin-Watson (1,78); persiste apenas heterocedasticidade moderada, detectada pelo teste de Breusch-Pagan ($p = 0,023$), compatível com a maior variabilidade natural esperada em espécimes de maior porte.

O tratamento da variável *year* ilustra a mesma lógica: embora estatisticamente significativa nesta amostra (mesmo controlando por espécie, ilha e sexo), foi descartada por não representar um atributo generalizável — os anos de coleta observados não estarão disponíveis para novas observações futuras, tornando a variável útil apenas para descrever esta amostra específica, e não para prever novos pinguins.

O modelo final permite estimar o comprimento da nadadeira a partir da espécie, da ilha e do sexo do indivíduo, sem depender de medidas morfológicas contínuas redundantes entre si. Embora a leve heterocedasticidade residual exija cautela na leitura de intervalos de predição para observações muito distantes do centro da amostra, a robustez da comparação por validação cruzada, aliada ao diagnóstico de multicolinearidade e de resíduos, sustenta esse modelo como a escolha mais adequada entre desempenho preditivo, parcimônia e interpretabilidade para a inferência morfológica dentro do intervalo de medidas catalogadas nas ilhas do arquipélago.

Referências

COHEN, J. Statistical Power Analysis for the Behavioral Sciences. 2. ed. Hillsdale, NJ: Lawrence Erlbaum Associates, 1988.

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, v. 10, n. 7, p. 1895–1923, 1998.

NADEAU, C.; BENGIO, Y. Inference for the generalization error. *Machine Learning*, v. 52, n. 3, p. 239–281, 2003.

SCHAFER, J. L. Multiple imputation: a primer. *Statistical Methods in Medical Research*, v. 8, n. 1, p. 3–15, 1999.

SUITS, D. B. Use of dummy variables in regression equations. *Journal of the American Statistical Association*, v. 52, n. 280, p. 548–551, 1957.