

Penguins Analysis

João Neves



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Disciplina: Estatística Aplicada – Período: 2026.1

Professores: Profa. Dra. Amanda Gomes; Prof. Dr. Jerfson Bruno; Prof. Dr. Gilberto Matos

Modelagem da Relação entre Características Morfológicas de Pingüins

João Vítor Neves, Darlan Almeida, Emerson Sulpino

Departamento de Ciência da Computação - UFCG

Resumo Este trabalho aplica a metodologia de regressão linear múltipla (MRLM) ao conjunto de dados *Palmer Penguins*, proveniente do programa de Pesquisa Ecológica de Longo Prazo (LTER) na Antártica Ocidental, com o objetivo de modelar o tamanho da nadadeira a partir das demais variáveis morfológicas e ecológicas a partir das espécies *Adelie*, *Chinstrap* e *Gentoo*. Realizamos uma análise exploratória, incluindo correlações, box-plots e verificação de dados ausentes, ajustamos um modelo inicial com todas as variáveis explicativas disponíveis e identificamos multicolinearidade entre a massa corporal e a espécie. Seleccionamos então um modelo final por meio (CITAR O CRITÉRIO), livre de multicolinearidade relevante, e verificamos seus pressupostos através de análise de resíduos. Por fim, para dois conjuntos de valores das variáveis explicativas, apresentamos os intervalos de confiança para o valor médio esperado da variável resposta e os intervalos de predição para novas observações, com interpretação prática de ambos.

Palavras-Chave: regressao linear multipla, multicolinearidade, selecao de modelos, palmer penguins, analise exploratoria, caracteristicas morfometricas

1. Introdução

[text]

Variável resposta:

Usaremos `flipper_length_mm` — o comprimento da nadadeira, em milímetros — como resposta. Queremos investigar e prever essa medida partir das demais informações disponíveis sobre o pinguim: espécie, ilha, medidas do bico, massa corporal, sexo e ano de coleta.

Pergunta formulada:

Entre pinguins semelhantes nas demais características consideradas, como o comprimento esperado da nadadeira varia com cada preditor, e quão bem o modelo prevê novos pinguins?

2. Metodologia

[text]

2.1 Modelo inicial de regressão linear múltipla

Seja y_i o tamanho da nadadeira do i -ésimo pinguim. O modelo inicial, com todas as variáveis explicativas disponíveis, é dado por

$$y_i = \beta_0 + \beta_1 tamBico + \beta_2 tamBico + \beta_3 profundBico + \beta_4 massaCorp + \beta_5 chinstrap + \beta_6 gentoo + \varepsilon_i,$$

em que *Chinstrap* e *Gentoo* são indicadoras da espécie do i -ésimo pinguim (*Adelie* como categoria de referência) e ε_i segue as suposições usuais do MRLM: média nula, variância constante, independência e normalidade. A multicolinearidade entre as variáveis explicativas foi avaliada pelo fator de inflação de variância, $VIF_j = 1/(1 - R^2_j)$, em que R^2_j é o coeficiente de determinação da regressão de X_j sobre as demais explicativas; $VIF_j > 10$ indica multicolinearidade severa. A seleção do modelo final entre os candidatos foi conduzida por procedimento *stepwise* baseado no Critério de (CITAR CRITERIO), $AIC = -2 \log(\hat{L}) + 2k$, priorizando, entre modelos de ajuste equivalente, aquele livre de multicolinearidade relevante.

3. Descrição da base

A base de dados Palmer Penguins possui $n = 344$ espécimes registrados

Table 1: Dicionário de variáveis

Variável	Tipo	Papel	Definição	Unidade
species	Categórica	Preditor	Espécie do pinguim (Adelie, Chinstrap, Gentoo)	
island	Categórica	Preditor	Ilha de observação (Dream, Torgersen, Biscoe)	
bill_length_mm	Numérica	Preditor	Comprimento do bico	milímetros
bill_depth_mm	Numérica	Preditor	Profundidade do bico	milímetros
flipper_length_mm	Numérica	Resposta	Comprimento da nadadeira	milímetros
body_mass_g	Numérica	Preditor	Massa corporal	gramas

Variável	Tipo	Papel	Definição	Unidade
sex	Categórica	Preditor	Sexo do pinguim (male, female)	
year	Inteira	Descartada	Ano em que a observação foi registrada	

4. Análise Exploratória

Table 2: Amostra dos dados

species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	sex	year
Adelie	Torgersen	39.1	18.7	181	3750	male	2007
Adelie	Torgersen	39.5	17.4	186	3800	female	2007
Adelie	Torgersen	40.3	18.0	195	3250	female	2007
Adelie	Torgersen	NA	NA	NA	NA	NA	2007
Adelie	Torgersen	36.7	19.3	193	3450	female	2007

Figura 1: Contagem de Indivíduos pelas Variáveis Qualitativas





Figura 2: Distribuição das Variáveis Numéricas por Espécie

Boxplots sobrepostos com dispersão de indivíduos



Os diagramas de caixa (boxplots) confirmam a consistência das distribuições morfométricas na amostra. As caixas interquartílicas evidenciam a amplitude do centro dos dados para cada medida física. Nota-se a semelhante distribuição, entre as espécies *Adelie* e *Chinstrap*, para características como massa corporal, tamanho da nadadeira, e profundidade do bico que pode ser explicada pela (CITAR PONTO ECOLOGICO E MORFOLOGICO). Por outro lado, a espécie *Gentoo* se distingue ...

4.2 Tratamento de dados

4.2.1 Variável Sexo Percebe-se que, na Figura 1, possuímos uma parcela de espécimes que não possuem seu sexo identificado. Com isso, avaliaremos o nível de importância dessa variável a fim de tomar uma decisão quanto à remoção dos espécimes com informações faltantes ou à inclusão desses espécimes ao modelo.

Considerando as seguintes hipóteses:

$$H_0 : \mu_{\text{male}} = \mu_{\text{female}}$$


$$H_1 : \mu_{\text{male}} \neq \mu_{\text{female}}$$

Ao realizarmos um teste t de Student para a variável descrita, rejeitamos a hipótese nula de igualdade entre as médias, por termos obtido $t = 4,801$ e $p < 0,001$. Há evidências suficientes que indicam uma associação entre o sexo e o tamanho da nadadeira.

Ao realizarmos a aplicação do Coeficiente de Cohen, demonstramos que a variável sexo possui alta relevância preditiva e explicativa em relação ao comprimento da nadadeira, o que inviabiliza a exclusão da coluna inteira do conjunto de dados.

A variável apresentou 11 registros ausentes (NaN), o que corresponde a aproximadamente 3,2% da base total. Na literatura de análise de dados, proporções de dados faltantes inferiores a 5% são frequentemente tratadas através da exclusão das observações, já que a perda de poder estatístico é negligenciável.


4.2.2 Variável Ano




A variável em questão, não contribui com a explicabilidade da variável resposta visto que, embora o gráfico revele uma sutil variação negativa na mediana do ano de 2007 e uma assimetria

na distribuição dos anos subsequentes (com maior concentração de pontos entre o terceiro e quarto quartis), essas nuances visuais não justificam a utilização dessa variável no modelo. A concentração assimétrica na porção superior das caixas reflete, na verdade, uma distribuição bimodal causada pela sobreposição das diferentes espécies na amostra anual, especificamente a presença da espécie Gentoo, cujos espécimes possuem dimensões naturalmente maiores. Dado que essa variação milimétrica interanual não oferece ganho preditivo ou explicativo relevante em comparação com as variáveis biológicas principais (*Sexo* e *Espécie*), a desconsideração da variável temporal *Ano* não contribuirá para perda significativa de informação.

4.3 Avaliação de correlação entre variáveis




A Figura 4 apresenta ...



Pela separação de espécies, fica clara a forte e positiva correlação entre a massa corporal do pinguim e o tamanho de sua nadadeira, isso para todas as três espécies avaliadas. Ademais, vê-se uma extensão da similaridade antes comprovada nos boxplots que as espécies *Adelia* e *Chinstrap* compartilham de características intrínsecas para tamanho da nadadeira e profundidade do bico

```
## <theme> List of 1
## $ plot.title: <ggplot2::element_text>
## ..@ family      : NULL
## ..@ face        : chr "bold"
## ..@ italic      : chr NA
## ..@ fontweight   : num NA
## ..@ fontwidth    : num NA
## ..@ colour      : NULL
## ..@ size        : num 11
## ..@ hjust       : num 0.6
## ..@ vjust       : NULL
## ..@ angle       : NULL
## ..@ lineheight   : NULL
## ..@ margin      : NULL
## ..@ debug       : NULL
## ..@ inherit.blank: logi FALSE
## @ complete: logi FALSE
## @ validate: logi TRUE
```



5. Seleção de Variáveis e Regressão dos modelos

[text] e [formula_modelo completo]

```
# Tratamento justificado anteriormente
dados_modelados <- dados |>
  select(-year) |>
  filter(!is.na(sex))
```

```
modelo_sem_especie <- lm(flipper_length_mm ~ bill_length_mm + bill_depth_mm + body_mass_g + island + sex)
modelo_completo <- lm(flipper_length_mm ~ bill_length_mm + bill_depth_mm + body_mass_g + species + island)
anova(modelo_sem_especie, modelo_completo)
```

```
## Analysis of Variance Table
##
```

```
## Model 1: flipper_length_mm ~ bill_length_mm + bill_depth_mm + body_mass_g +
##      island + sex
## Model 2: flipper_length_mm ~ bill_length_mm + bill_depth_mm + body_mass_g +
##      species + island + sex
##      Res.Df      RSS Df Sum of Sq      F      Pr(>F)
## 1      326 10820.7
## 2      324  8768.5   2    2052.2 37.914 1.602e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Para validar estatisticamente a inclusão da variável qualitativa correspondente à espécie do pinguim, realizou-se uma Análise de Variância (ANOVA) comparando um modelo restrito (sem a referida variável) e o modelo completo. O teste F indicou uma redução significativa na soma dos quadrados dos resíduos (RSS) no modelo completo. Com uma estatística $F = 37.914$ e um valor de $p < 0.001$, rejeitamos a hipótese nula de que os dois modelos possuem a mesma capacidade explicativa. Conclui-se, portanto, que a característica biológica da espécie contribui de forma estatisticamente significativa para a predição do comprimento da nadadeira, justificando sua permanência na regressão final.

```
# Ajustando o Modelo Vencedor descoberto pelo pipeline de validação cruzada
modelo_vencedor <- lm(
  flipper_length_mm ~ species + bill_length_mm + bill_depth_mm + body_mass_g,
  data = dados_modelados
)

summary(modelo_vencedor)
```

```
##
## Call:
## lm(formula = flipper_length_mm ~ species + bill_length_mm + bill_depth_mm +
##      body_mass_g, data = dados_modelados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -17.8017  -2.9737  -0.1342   3.2969  16.4271
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    1.367e+02  5.168e+00  26.456 < 2e-16 ***
## speciesChinstrap 1.426e+00  1.442e+00   0.989  0.32344
## speciesGentoo    1.891e+01  2.289e+00   8.262 3.62e-15 ***
## bill_length_mm   4.073e-01  1.235e-01   3.299  0.00108 **
## bill_depth_mm    9.194e-01  3.402e-01   2.702  0.00724 **
## body_mass_g      5.583e-03  8.653e-04   6.452 3.98e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.229 on 327 degrees of freedom
## Multiple R-squared:  0.8629, Adjusted R-squared:  0.8608
## F-statistic: 411.6 on 5 and 327 DF,  p-value: < 2.2e-16
```

Seleção do Modelo via Validação Cruzada Exaustiva Para determinar a combinação ideal de variáveis preditoras, realizou-se preliminarmente uma busca exaustiva (Best Subset Selection) avaliada por Validação Cruzada K-Fold ($k = 5$). O modelo que minimizou o Erro Quadrático Médio (RMSE = 5.29

mm) foi composto pelas variáveis: `species`, `bill_length_mm`, `bill_depth_mm` e `body_mass_g`. Para garantir a robustez dessa escolha, os resíduos dos folds foram submetidos a um teste t pareado com correção de Nadeau-Bengio. O modelo selecionado demonstrou superioridade estatisticamente significativa ($p = 0.02$) contra um modelo restrito apenas a variáveis contínuas, consolidando a importância de mesclar a morfologia do bico e da massa com a categorização da espécie. As variáveis `sex` e `island` foram descartadas por não apresentarem ganho preditivo significativo nesta configuração.