



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Disciplina: Estatística Aplicada – Período: 2026.1

Professores: Profa. Dra. Amanda Gomes; Prof. Dr. Jerfson Bruno; Prof. Dr. Gilberto Matos

Modelagem da Relação entre Características Morfológicas de Pinguins

João Vítor Neves, Darlan Almeida, Emerson Sulpino

Departamento de Ciência da Computação - UFCG

Resumo Este trabalho aplica a metodologia de regressão linear múltipla (MRLM) ao conjunto de dados *Palmer Penguins*, proveniente do programa de Pesquisa Ecológica de Longo Prazo (LTER) na Antártica Ocidental, com o objetivo de modelar o comprimento da nadadeira de pinguins das espécies *Adelie*, *Chinstrap* e *Gentoo* a partir de variáveis morfológicas e categóricas. Realizou-se uma análise exploratória das distribuições, correlações e dados ausentes, seguida do ajuste de um modelo completo e da comparação de subconjuntos de preditores por validação cruzada *K-Fold*. O modelo selecionado, composto por espécie, comprimento do bico, profundidade do bico e massa corporal, apresentou o menor RMSE médio entre os candidatos avaliados. A comparação por teste *t* pareado com correção de Nadeau-Bengio reforçou a superioridade desse modelo em relação ao modelo apenas quantitativo, enquanto os diagnósticos indicaram boa capacidade explicativa, com presença de heterocedasticidade e leve afastamento da normalidade dos resíduos. Assim, o relatório preserva a seleção do modelo como uma decisão baseada no conjunto das evidências: desempenho preditivo, parcimônia, contribuição estatística da espécie e avaliação dos pressupostos.

Palavras-Chave: regressao linear multipla, multicolinearidade, selecao de modelos, palmer penguins, analise exploratoria, caracteristicas morfometricas

Contents

Modelagem da Relação entre Características Morfológicas de Pinguins	1
João Vítor Neves, Darlan Almeida, Emerson Sulpino	1
1. Introdução	3
Objetivos da análise	3
Variável resposta:	3
2. Metodologia	3
2.1 Modelo inicial de regressão linear múltipla	3
2.2 Diagnóstico de Suposições	4
2.3 Critérios de Seleção e Validação Cruzada	4
3. Descrição da base	4
4. Análise Exploratória	4
4.1 Distribuição das variáveis	4
4.2 Tratamento de dados	6
4.3 Avaliação de correlação entre variáveis	7
5. Seleção de Variáveis e Regressão dos modelos	8
6. Análise de Resíduos	11
7. Previsão e Incerteza	12
8. Conclusões	13

1. Introdução

Este trabalho utiliza o conjunto de dados *Palmer Penguins*, coletado pelo programa de Pesquisa Ecológica de Longo Prazo (LTER) entre 2007 e 2009, para investigar quais características morfológicas e categóricas explicam o comprimento da nadadeira dos indivíduos amostrados. Diferentemente de uma descrição puramente correlacional, buscamos um modelo de regressão linear múltipla (MRLM) que permita interpretar efeitos parciais — isto é, o efeito de cada variável mantendo as demais constantes —, avaliar a adequação de suas suposições e quantificar a incerteza tanto para o valor médio esperado da resposta quanto para novas observações individuais.

Objetivos da análise

- Caracterizar exploratoriamente as variáveis morfológicas e categóricas disponíveis;
- Ajustar um modelo inicial com todas as variáveis explicativas e avaliar multicolinearidade;
- Selecionar, entre modelos candidatos, aquele com melhor equilíbrio entre desempenho preditivo, parcimônia e colinearidade controlada dentro de limites aceitáveis;
- Verificar as suposições do MRLM por meio de diagnóstico de resíduos;
- Construir intervalos de confiança e de predição para cenários específicos, com interpretação prática.

Variável resposta:

Usaremos `flipper_length_mm` — o comprimento da nadadeira, em milímetros — como resposta. Queremos investigar e prever essa medida partir das demais informações disponíveis sobre o pinguim: espécie, ilha, medidas do bico, massa corporal, sexo e ano de coleta.

Pergunta formulada:

Entre pinguins semelhantes nas demais características consideradas, como o comprimento esperado da nadadeira varia com cada preditor, e quão bem o modelo prevê novos pinguins?

2. Metodologia

A análise estrutura-se em quatro etapas: (i) exploração dos dados, ausências e correlações; (ii) ajuste do modelo inicial e avaliação de multicolinearidade; (iii) seleção do modelo final via validação cruzada k -fold e testes de hipótese; e (iv) diagnóstico dos pressupostos dos resíduos, complementado pela construção de intervalos de confiança e de predição.

2.1 Modelo inicial de regressão linear múltipla

Seja y_i o comprimento da nadadeira, em milímetros, do i -ésimo pinguim. Após a retirada da variável `year`, avaliada exploratoriamente como pouco informativa para a resposta, e a remoção dos registros sem identificação de sexo, o modelo completo inicial foi definido com as variáveis morfológicas contínuas e as variáveis categóricas disponíveis:

$$y_i = \beta_0 + \beta_1 \text{tamBico}_i + \beta_2 \text{profundBico}_i + \beta_3 \text{massaCorp}_i + \beta_4 \text{chinstrap}_i \\ + \beta_5 \text{gentoo}_i + \beta_6 \text{dream}_i + \beta_7 \text{torgersen}_i + \beta_8 \text{male}_i + \varepsilon_i.$$

Nesse modelo, `compBico`, `profundBico` e `massaCorp` representam, respectivamente, o comprimento do bico, a profundidade do bico e a massa corporal. As variáveis `chinstrap` e `gentoo` são indicadoras da espécie, tendo *Adelie* como categoria de referência; `dream` e `torgersen` são indicadoras da ilha, tendo *Biscoe* como referência; e `male` representa o sexo masculino, tendo *female* como referência. O termo ε_i representa o

erro aleatório e segue as suposições usuais do MRLM: média nula, variância constante, independência e normalidade aproximada.

A multicolinearidade entre as variáveis explicativas foi avaliada pelo fator de inflação de variância, $VIF_j = 1/(1-R_j^2)$, em que R_j^2 é o coeficiente de determinação da regressão de X_j sobre as demais explicativas; valores de $VIF_j > 10$ foram tratados como indicativo de multicolinearidade severa. A seleção do modelo final foi conduzida pela comparação de subconjuntos de preditores por validação cruzada K -Fold ($k = 5$), utilizando o RMSE médio como métrica principal de desempenho preditivo. O AIC e o BIC foram considerados como medidas auxiliares de ajuste e parcimônia, sem substituir a decisão baseada na validação cruzada e nos testes comparativos entre modelos.

2.2 Diagnóstico de Suposições

A validação do modelo vencedor ancorou-se na verificação gráfica e formal dos pressupostos clássicos dos resíduos:

- **Linearidade e Homocedasticidade:** Avaliadas pelo diagrama de resíduos versus valores ajustados e testadas pelo Teste de Breusch-Pagan (H_0 : variância constante).
- **Normalidade dos Erros:** Inspecionada pelo gráfico Q-Q Plot e submetida ao teste formal de Jarque-Bera (H_0 : distribuição normal dos erros).
- **Independência dos Erros:** Verificada pelo Teste de Durbin-Watson (H_0 : ausência de autocorrelação nos resíduos).

2.3 Critérios de Seleção e Validação Cruzada

Para prevenir o superajuste (*overfitting*) e priorizar a parcimônia, o Critério de Informação de Akaike (AIC) e o Critério Bayesiano de Schwarz (BIC) foram reportados como medidas complementares de ajuste do modelo final, embora a comparação formal entre os subconjuntos candidatos tenha sido conduzida por validação cruzada K -fold (RMSE) e teste t pareado com correção de Nadeau-Bengio, apresentados a seguir.

A capacidade de generalização foi mensurada por Validação Cruzada K -Fold ($k = 5$) com base no Erro Quadrático Médio de Predição (RMSE). Para comparar os modelos concorrentes neutralizando a dependência entre as dobras de treino e teste, aplicou-se o teste t pareado com a correção de variância de Nadeau-Bengio:

$$\sigma_{\text{corrigida}}^2 = \left(\frac{1}{k} + \frac{n_{\text{teste}}}{n_{\text{treino}}} \right) s_{\text{diferença}}^2$$

3. Descrição da base

A base de dados Palmer Penguins possui $n = 344$ espécimes registrados

4. Análise Exploratória

4.1 Distribuição das variáveis

Os diagramas de caixa da Figura @ref(fig: boxplots) confirmam a consistência das distribuições morfométricas na amostra. As caixas interquartílicas evidenciam a amplitude do centro dos dados para cada medida física. Nota-se a semelhante distribuição, entre as espécies *Adelie* e *Chinstrap*, para características como massa corporal, tamanho da nadadeira e profundidade do bico, fato que pode ser explicado pela **convergência ecomorfológica e sobreposição parcial de nicho trófico entre ambas as espécies**, que compartilham hábitos de forrageamento de menor profundidade em relação aos *Gentoo*. Por outro lado, a

Table 1: Dicionário de variáveis

Variável	Tipo	Papel	Definição	Unidade
species	Catégorica	Preditor	Espécie do pinguim (Adelie, Chinstrap, Gentoo)	
island	Catégorica	Preditor	Ilha de observação (Dream, Torgersen, Biscoe)	
bill_length_mm	Numérica	Preditor	Comprimento do bico	milímetros
bill_depth_mm	Numérica	Preditor	Profundidade do bico	milímetros
flipper_length_mm	Numérica	Resposta	Comprimento da nadadeira	milímetros
body_mass_g	Numérica	Preditor	Massa corporal	gramas
sex	Catégorica	Preditor	Sexo do pinguim (male, female)	
year	Inteira	Descartada	Ano em que a observação foi registrada	




Figure 1: Distribuição de variáveis qualitativas




Figure 2: Distribuição de variáveis quantitativas

espécie *Gentoo* se distingue acentuadamente por apresentar maior massa corporal e nadadeiras significativamente mais longas (gigantismo relativo dentro do gênero), porém acompanhadas por bicos proporcionalmente mais rasos (*bill depth*).

4.2 Tratamento de dados

4.2.1 Variável Sexo Percebe-se que, na Figura 1, possuímos uma parcela de espécimes que não possuem seu sexo identificado. Com isso, avaliaremos o nível de importância dessa variável a fim de tomar uma decisão quanto à remoção dos espécimes com informações faltantes ou à inclusão desses espécimes ao modelo.

Considerando as seguintes hipóteses:

$$H_0 : \mu_{\text{male}} = \mu_{\text{female}}$$

$$H_1 : \mu_{\text{male}} \neq \mu_{\text{female}}$$

Ao realizarmos um teste t de Student para a variável descrita, rejeitamos a hipótese nula de igualdade entre as médias, por termos obtido $t = 4,801$ e $p < 0,001$. Há evidências suficientes que indicam uma associação entre o sexo e o tamanho da nadadeira.

Ao realizarmos a aplicação do Coeficiente de Cohen, demonstramos que a variável sexo possui alta relevância preditiva e explicativa em relação ao comprimento da nadadeira, o que inviabiliza a exclusão da coluna inteira do conjunto de dados.

A variável apresentou 11 registros ausentes (NaN), o que corresponde a aproximadamente 3,2% da base total. Na literatura de análise de dados, proporções de dados faltantes inferiores a 5% são frequentemente tratadas através da exclusão das observações, já que a perda de poder estatístico é negligenciável.




Figure 3: Distribuição do tamanho da nadadeira por Ano

4.2.2 Variável Ano A variável *Ano*, da Figura 3, não contribui com a explicabilidade da variável resposta visto que, embora o gráfico revele uma sutil variação negativa na mediana do ano de 2007 e uma assimetria na distribuição dos anos subsequentes (com maior concentração de pontos entre o terceiro e quarto quartis), essas nuances visuais não justificam a utilização dessa variável no modelo. A concentração assimétrica na porção superior das caixas reflete, na verdade, uma distribuição bimodal causada pela sobreposição

das diferentes espécies na amostra anual, especificamente a presença da espécie Gentoo, cujos espécimes possuem dimensões naturalmente maiores. Dado que essa variação milimétrica interanual não oferece ganho preditivo ou explicativo relevante em comparação com as variáveis biológicas principais (*Sexo* e *Espécie*), a desconsideração da variável temporal *Ano* não contribuirá para perda significativa de informação.

4.3 Avaliação de correlação entre variáveis






Figure 4: Mapa de calor entre variáveis

A Figura 4 apresenta a matriz de correlação de Pearson entre as variáveis numéricas contínuas. Observa-se uma forte correlação positiva entre o comprimento da nadadeira (*flipper_length_mm*) e a massa corporal (*body_mass_g*) ($r = 0,87$), evidenciando que a massa é o principal preditor linear contínuo do tamanho do apêndice. O comprimento do bico (*bill_length_mm*) também exibe correlação positiva considerável ($r = 0,65$) com a variável resposta. Em contrapartida, a profundidade do bico (*bill_depth_mm*) apresenta correlação negativa com a nadadeira ($r = -0,58$), um comportamento aparente causado pela presença da espécie *Gentoo*, cujos indivíduos possuem nadadeiras longas e bicos finos.



Pela separação de espécies, fica clara a forte e positiva correlação entre a massa corporal do pinguim e o tamanho de sua nadadeira, isso para todas as três espécies avaliadas. Ademais, vê-se uma extensão da similaridade antes comprovada nos boxplots que as espécies *Adelia* e *Chinstrap* compartilham de características intrínsecas para tamanho da nadadeira e profundidade do bico



5. Seleção de Variáveis e Regressão dos modelos

A partir do modelo inicial apresentado na Seção 2.1, com todas as variáveis explicativas disponíveis (exceto os espécimes sem sexo identificado, tratados na Seção 4.2.1), construímos o Modelo Completo como ponto de partida para a seleção de variáveis:

$$y_i = \beta_0 + \beta_1 \text{tamBico}_i + \beta_2 \text{profundBico}_i + \beta_3 \text{massaCorp}_i + \beta_4 \text{chinstrap}_i + \beta_5 \text{gentoo}_i + \beta_6 \text{dream}_i + \beta_7 \text{torgersen}_i + \beta_8 \text{male}_i + \varepsilon_i.$$

em que *Chinstrap* e *Gentoo* são indicadoras da espécie (*Adelia* como referência), *Dream* e *Torgersen* são indicadoras da ilha (*Biscoe* como referência) e *male* é indicadora do sexo (*female* como referência). Antes de comparar subconjuntos de preditores por validação cruzada (Seção 5.1), avaliamos primeiro se a variável espécie — apontada na análise exploratória (Seções 4.1 e 4.3) como fortemente associada às demais medidas morfológicas — de fato acrescenta poder explicativo, comparando por ANOVA o Modelo Completo contra sua versão restrita sem espécie.

Table 2: Análise de Variância comparando o modelo restrito e o completo.

Modelo	GL Res.	RSS	GL	Soma dos Quadrados	Estat. F	Valor-p
Modelo Sem Espécie	326	10820.65	NA	NA	NA	NA
Modelo Com Espécie	324	8768.47	2	2052.18	37.91	< 0,001

Para validar estatisticamente a inclusão da variável qualitativa correspondente à espécie do pinguim, realizou-se uma Análise de Variância (ANOVA) comparando um modelo restrito (sem a referida variável) e o modelo completo. O teste F indicou uma redução significativa na soma dos quadrados dos resíduos (RSS) no modelo completo. Com uma estatística $F = 37.914$ e um valor de $p < 0.001$, rejeitamos a hipótese nula de que os dois modelos possuem a mesma capacidade explicativa. Conclui-se, portanto, que a característica biológica

Table 4: Medidas globais de ajuste do modelo vencedor.

Medida	Valor
R^2 ajustado	0.861
AIC	2054.710
BIC	2081.370

da espécie contribui de forma estatisticamente significativa para a predição do comprimento da nadadeira, justificando sua permanência na regressão final.

Table 3: Estimativas dos coeficientes do modelo vencedor.

Variável	Estimativa	Erro Padrão	Estatística t	Valor-p
Intercepto	136.7308	5.1683	26.4558	< 0,001
Espécie: Chinstrap	1.4260	1.4420	0.9889	0,3234391
Espécie: Gentoo	18.9123	2.2891	8.2618	< 0,001
Comprimento do Bico	0.4073	0.1235	3.2992	0,0010764
Profundidade do Bico	0.9194	0.3402	2.7024	0,0072433
Massa Corporal	0.0056	0.0009	6.4517	< 0,001

O modelo vencedor apresentou R^2 ajustado de 0,861, indicando que aproximadamente 86,1% da variabilidade observada no comprimento da nadadeira é explicada pelas variáveis incluídas na regressão. Os valores de AIC (2054.71) e BIC (2081.37) são apresentados como medidas complementares de ajuste e parcimônia do modelo selecionado. Como esses critérios foram calculados apenas para o modelo final, eles não foram utilizados para comparar os modelos candidatos; a seleção foi baseada no menor RMSE obtido por validação cruzada.

5.1 Seleção do Modelo via Validação Cruzada Exaustiva Para determinar a combinação ideal de variáveis preditoras, realizou-se preliminarmente uma busca exaustiva, pela combinação de variáveis à distintos modelos, avaliada por Validação Cruzada K-Fold ($k = 5$). O modelo que minimizou o Erro Quadrático Médio (RMSE = 5.29 mm) foi composto pelas variáveis: species, bill_length_mm, bill_depth_mm e body_mass_g. Para garantir a robustez dessa escolha, os resíduos dos folds foram submetidos a um teste t pareado com correção de Nadeau-Bengio, o qual ajusta a variância estimada para compensar a dependência entre folds, buscando evitar a inflação de falsos positivos. O modelo selecionado demonstrou superioridade estatisticamente significativa ($p = 0.02$) contra um modelo restrito apenas a variáveis contínuas, consolidando a importância de mesclar a morfologia do bico e da massa com a categorização da espécie. As variáveis sex e island foram descartadas por não apresentarem ganho preditivo significativo nesta configuração.

Table 5: Comparativo de Desempenho Preditivo entre Subconjuntos de Variáveis

Modelo	Variáveis Preditores	RMSE Médio (K-Fold)
Vencedor (Completo)	Espécie, Bico (Comprimento e Profundidade), Massa	5.29 mm
Modelo A (Qualitativo)	Espécie, Ilha, Sexo	5.77 mm
Modelo B (Quantitativo)	Bico (Comprimento e Profundidade), Massa	5.86 mm

Table 6: Fator de Inflação da Variância (VIF) do modelo vencedor.

Variável	VIF
species_Chinstrap	4.115
species_Gentoo	14.654
bill_length_mm	5.534
bill_depth_mm	5.449
body_mass_g	5.894

5.2 Diagnóstico de Multicolinearidade do Modelo Vencedor A variável indicadora referente à espécie *Gentoo* apresenta $VIF = 14,65$, ultrapassando o limiar de severidade ($VIF > 10$) definido na Seção 2.1, enquanto as demais variáveis permanecem em um patamar moderado (VIF entre 4 e 6). Esse resultado decorre da forte associação entre a espécie *Gentoo* e as variáveis `body_mass_g` e `bill_depth_mm`: indivíduos dessa espécie apresentam massa corporal média de 5.092g, cerca de 37% acima de *Adelie* (3.706g) e *Chinstrap* (3.733g), e profundidade de bico média de 15,0mm, sensivelmente menor que os cerca de 18,3–18,4mm observados nas outras duas espécies. Ainda assim, entre os subconjuntos avaliados na Seção 5.1, o modelo vencedor apresentou o menor RMSE médio via validação cruzada, e sua remoção da variável espécie (Modelo B) resultou em desempenho preditivo inferior. Optou-se, portanto, por manter a variável, reconhecendo que a colinearidade residual associada a *Gentoo* limita a precisão da estimativa isolada desse coeficiente, sem comprometer a capacidade preditiva geral do modelo.

Complementarmente, a comparação entre o modelo vencedor e o Modelo A (Qualitativo: espécie, ilha e sexo) não indicou diferença estatisticamente significativa de desempenho preditivo ($p = 0,14$), e a comparação entre o Modelo A e o Modelo B (Quantitativo) também não foi significativa ($p = 0,79$). Em conjunto, esses três testes sugerem que ilha e sexo carregam pouca informação preditiva adicional sobre o comprimento da nadadeira depois de considerar espécie e as medidas contínuas, reforçando a decisão de excluí-las do modelo final por parcimônia.

6. Análise de Resíduos




Figure 5: Gráficos de diagnóstico de resíduos

Table 7: Testes Formais de Diagnóstico dos Resíduos do Modelo Vencedor.

Teste Diagnóstico	Premissa Avaliada	Estatística	Valor-p
Breusch-Pagan	Homocedasticidade	15.4721	0,0085247
Jarque-Bera	Normalidade	7.1135	0,0285313
Durbin-Watson	Independência (Autocorr.)	1.7715	0,0149767

A Figura 5 ilustra o diagnóstico de resíduos e a tabela 7 apresenta os resultados dos testes estatísticos formais aplicados aos resíduos do modelo selecionado. A análise indica que, ao nível de 5% de significância, houve rejeição das hipóteses nulas para as três premissas clássicas do modelo de Mínimos Quadrados Ordinários.

Com um p-valor de 0,0085, constata-se a presença de heterocedasticidade estrutural pela checagem de homocedasticidade do teste de *Breusch-Pagan*. É notável quando percebe-se que a variância dos resíduos não é constante, mas sim influenciada pelos valores ajustados da variável resposta. Considerando o contexto

biológico, é esperado que espécimes maiores apresentem uma variabilidade natural superior à de espécimes menores.

Outrossim, o resultado do teste de *Jarque-Bera* com p-valor igual à 0,0285 aponta para desvios na distribuição dos resíduos em relação a uma curva normal perfeita. Contudo, considerando o tamanho da amostra após a limpeza dos dados, o Teorema do Limite Central atua para atenuar o impacto desse desvio, tornando as estimativas dos coeficientes assintoticamente válidas, considerando os desvios caudais existentes.




Figure 6: Distribuição de resíduos por espécie

Como já previsto pelo contexto da base de dados analisada, na Figura 6 nota-se não apenas a assimetria de diferentes espécimes representadas no gráfico, como a tendência da espécie maior *Gentoo* ser menos dispersa que as demais espécies *Adelie* e *Chinstrap*

7. Previsão e Incerteza

Com o modelo vencedor, foram construídos três cenários representativos, correspondentes a um pinguim típico de cada espécie da base de dados. A Tabela 9 descreve as características morfológicas adotadas em cada cenário, e a Tabela 10 apresenta as estimativas do comprimento da nadadeira juntamente com seus respectivos intervalos de confiança (IC) e de predição (IP).

Table 8: Cenários hipotéticos utilizados na previsão.

Cenário	Espécie	Comp. Bico (mm)	Prof. Bico (mm)	Massa (g)
Pinguim A	Adelie	38.8	18.3	3700
Pinguim B	Chinstrap	48.8	18.4	3730
Pinguim C	Gentoo	47.5	15.0	5090

Table 9: Intervalos de confiança e de predição para o comprimento da nadadeira.

Cenário	Intervalo	Estimativa	Inferior	Superior
Pinguim A	IC 95% da média	190.02	189.16	190.87
Pinguim B	IC 95% da média	195.77	194.53	197.02
Pinguim C	IC 95% da média	217.20	216.25	218.14
Pinguim A	IP 95% individual	190.02	179.69	200.34
Pinguim B	IP 95% individual	195.77	185.41	206.14
Pinguim C	IP 95% individual	217.20	206.87	227.53

O intervalo de confiança (IC) captura a incerteza sobre o comprimento médio esperado de *todos* os pinguins com aquele conjunto de preditores; o intervalo de previsão (IP) captura a incerteza para *um único* pinguim novo, incorporando também a variação residual do modelo — por isso é sempre mais amplo, e é o apropriado para estimar um indivíduo específico. Essa diferença aparece claramente nos três cenários: o IP é de 4 a 5 vezes mais largo que o IC correspondente (por exemplo, no Pinguim A, 11,71mm de amplitude contra apenas 1,71mm), refletindo que o IC responde apenas pela incerteza da média, enquanto o IP soma a ela a variabilidade individual não explicada pelo modelo.

O IC do Pinguim A (*Adelie*) é o mais estreito dos três (189,16 a 190,87mm), consequência do grande número de indivíduos dessa espécie na amostra ($n = 146$ após o tratamento da Seção 4.2.1). Além disso, os três cenários não se sobrepõem em nenhum dos dois tipos de intervalo, reforçando numericamente o que já havíamos observado nos boxplots da Seção 4.1 e no gráfico de resíduos por espécie da Seção 6: a espécie mantém forte poder discriminativo sobre o comprimento da nadadeira mesmo depois de controladas as medidas do bico e a massa corporal.

8. Conclusões

As variáveis morfológicas dos pinguins do arquipélago de Palmer mostram-se fortemente associadas entre si e nitidamente agrupadas por espécie, refletindo distinções anatômicas claras de massa e estrutura de bico. A avaliação inicial com todas as variáveis explicativas (incluindo dados geográficos e biológicos complementares) revelou redundâncias, uma vez que características como a ilha e o sexo não agregavam ganho preditivo estatisticamente significativo para justificar a complexidade do modelo.

O modelo final, selecionado por busca exaustiva via Validação Cruzada (K-Fold) para a minimização do erro (RMSE), utiliza a espécie, a massa corporal e as dimensões do bico (comprimento e profundidade) como preditores. Esse modelo parcimonioso preservou um excelente poder explicativo (R^2 ajustado = 0.861). Ao contrário de cenários perfeitamente teóricos, os pressupostos clássicos de MQO foram testados e revelaram leves violações de homocedasticidade, normalidade e independência dos resíduos. Contudo, essa heterocedasticidade reflete a variabilidade natural da biologia observada (onde espécimes maiores tendem a apresentar maior variância estrutural), não acarretando vies nas estimativas.

O modelo permite estimar o comprimento da nadadeira a partir do porte físico da ave e de sua espécie. Embora a estrutura dos resíduos exija certa cautela analítica ao estabelecer intervalos de predição clássicos para novas observações individuais, a robustez da validação metodológica comprova que se trata de uma ferramenta preditiva altamente confiável para a inferência morfológica dentro do intervalo de medidas catalogadas nas ilhas do arquipélago.