



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Disciplina: Estatística Aplicada – Período: 2026.1

Professores: Profa. Dra. Amanda Gomes; Prof. Dr. Jerfson Bruno; Prof. Dr. Gilberto Matos

Modelagem da Relação entre Características Morfológicas de Pinguins

João Vítor Neves, Darlan Almeida, Emerson Sulpino

Departamento de Ciência da Computação - UFCG

Resumo Este trabalho aplica a metodologia de regressão linear múltipla (MRLM) ao conjunto de dados *Palmer Penguins*, proveniente do programa de Pesquisa Ecológica de Longo Prazo (LTER) na Antártica Ocidental, com o objetivo de modelar o tamanho da nadadeira a partir das demais variáveis morfológicas e ecológicas a partir das espécies *Adelie*, *Chinstrap* e *Gentoo*. Realizamos uma análise exploratória, incluindo correlações, box-plots e verificação de dados ausentes, ajustamos um modelo inicial com todas as variáveis explicativas disponíveis e identificamos multicolinearidade entre a massa corporal e a espécie. Selecionamos então um modelo final por meio (CITAR O CRITÉRIO), livre de multicolinearidade relevante, e verificamos seus pressupostos através de análise de resíduos. Por fim, para dois conjuntos de valores das variáveis explicativas, apresentamos os intervalos de confiança para o valor médio esperado da variável resposta e os intervalos de predição para novas observações, com interpretação prática de ambos.

Palavras-Chave: regressao linear multipla, multicolinearidade, selecao de modelos, palmer penguins, analise exploratoria, caracteristicas morfometricas

1. Introdução

[text]

Variável resposta:

Usaremos `flipper_length_mm` — o comprimento da nadadeira, em milímetros — como resposta. Queremos investigar e prever essa medida partir das demais informações disponíveis sobre o pinguim: espécie, ilha, medidas do bico, massa corporal, sexo e ano de coleta.

Pergunta formulada:

Entre pinguins semelhantes nas demais características consideradas, como o comprimento esperado da nadadeira varia com cada preditor, e quão bem o modelo prevê novos pinguins?

Análise Exploratória

```
paleta_especies <- c('#4C72B0', '#DD8452', '#55A868')

dados_longos <- dados |>
  pivot_longer(
    cols = c(bill_length_mm, bill_depth_mm, flipper_length_mm, body_mass_g),
    names_to = "medida",
    values_to = "valor"
  )

ggplot(dados_longos, aes(x = species, y = valor, color = species)) +

  geom_boxplot(aes(fill = species), alpha = 0.12, width = 0.58,
    outlier.shape = NA, linewidth = 0.55) +

  geom_jitter(width = 0.14, alpha = 0.55, size = 1.35) +

  facet_wrap(~ medida, scales = "free_y", ncol = 2) +

  scale_color_manual(values = paleta_especies) +
  scale_fill_manual(values = paleta_especies) +

  labs(
    title = "Figura 2: Distribuição das Variáveis Numéricas por Espécie",
    subtitle = "Boxplots sobrepostos com dispersão de indivíduos",
    x = NULL,
    y = "Valor",
    color = "Espécie"
  ) +

  theme_minimal() +
  theme(
    plot.title = element_text(size = 14, face = "bold", hjust = 0.5),
    plot.subtitle = element_text(size = 11, hjust = 0.5, color = "grey40"),


    strip.text = element_text(face = "bold", size = 11),

    panel.grid.minor = element_blank(),
```

```
legend.position = "bottom"
) +
guides(fill = "none")
```

Figura 2: Distribuição das Variáveis Numéricas por Espécie

Boxplots sobrepostos com dispersão de indivíduos



Os diagramas de caixa (boxplots) confirmam a consistência das distribuições morfométricas na amostra. As caixas interquartílicas evidenciam a amplitude do centro dos dados para cada medida física. Nota-se a semelhante distribuição, entre as espécies *Adelie* e *Chinstrap*, para características como massa corporal, tamanho da nadadeira, e profundidade do bico que pode ser explicada pela (CITAR PONTO ECOLOGICO E MORFOLOGICO). Por outro lado, a espécie *Gentoo* se distingue ...

Tratamento de dados

Percebe-se que, na Figura 1, possuímos uma parcela de espécimes que não possuem seu sexo identificado. Com isso, avaliaremos o nível de importância dessa variável afim de tomar uma decisão quanto à remoção dos espécimes com informações faltantes ou à inclusão desses espécimes ao modelo

Considerando as seguintes hipóteses : $H_0 : \mu_{male} = \mu_{female}$ $H_1 : \mu_{male} \neq \mu_{female}$

Ao realizarmos um teste t de Student entre para a variável descrita, rejeitamos a hipótese nula de igualdade entre as médias, por termos obtido $t = 4,801$ e $p < 0,001$. Há evidências suficientes que indicam uma associação entre o sexo e o tamanho da nadadeira.

Ao realizarmos a aplicação do Coeficiente de Cohen, demonstramos que a variável *sexo* possui alta relevância preditiva e explicativa em relação ao comprimento da nadadeira, o que inviabiliza a exclusão da coluna inteira do conjunto de dados.

A variável apresentou 11 registros ausentes (NaN), o que corresponde a aproximadamente 3,2% da base total. Na literatura de análise de dados, proporções de dados faltantes inferiores a 5% são frequentemente tratadas através da exclusão das observações, já que a perda de poder estatístico é negligenciável.

Além disso, optou-se por não aplicar técnicas de imputação para inferir o sexo desses 11 espécimes. Como as características morfológicas possuem forte correlação com o sexo, deduzir essa categoria a partir de outras variáveis introduziria um viés de circularidade, inflando artificialmente as correlações na etapa de modelagem. Portanto, visando preservar a integridade da distribuição original e a confiabilidade das inferências estatísticas, as 11 tuplas contendo valores ausentes foram removidas, mantendo-se a coluna em sua totalidade para as etapas subsequentes.


Por fim, iremos fazer uma filtragem de uma das variáveis explicativas presente na base de dados.

A variável em questão, não contribui com a explicabilidade da variável resposta: tamanho da nadadeira, visto que

```
ggplot(dados, aes(x = factor(year), y = flipper_length_mm, color = factor(year))) +  
  
  geom_jitter(width = 0.2, alpha = 0.4, size = 1.5) +  
  geom_boxplot(fill = NA, outlier.shape = NA, color = "black", linewidth = 0.6, width = 0.5) +  
  
  scale_color_manual(values = c("2007" = "#7f8c8d", "2008" = "#95a5a6", "2009" = "#bdc3c7")) +  
  
  labs(  
    title = "Figura 3: Estabilidade Temporal do Comprimento da Nadadeira",  
    subtitle = "A distribuição da variável resposta permanece constante ao longo dos anos",  
    x = "Ano da Coleta",  
    y = "Comprimento da Nadadeira (mm)"  
  ) +  
  
  theme_minimal() +  
  theme(  
    plot.title = element_text(size = 13, face = "bold", hjust = 0.5),  
    plot.subtitle = element_text(size = 10, color = "grey40", hjust = 0.5),  
    legend.position = "none", # Oculta a legenda pois o eixo X já explica  
    panel.grid.minor = element_blank()  
  )
```

Figura 3: Estabilidade Temporal do Comprimento da Nadadeira

A distribuição da variável resposta permanece constante ao longo dos anos



Embora o gráfico revele uma sutil variação negativa na mediana do ano de 2007 e uma assimetria na distribuição dos anos subsequentes (com maior concentração de pontos entre o terceiro e quarto quartis), essas nuances visuais não justificam a utilização dessa variável no modelo. A concentração assimétrica na porção superior das caixas reflete, na verdade, uma distribuição bimodal causada pela sobreposição das diferentes espécies na amostra anual, especificamente a presença da espécie Gentoo, cujos espécimes possuem dimensões naturalmente maiores. Dado que essa variação milimétrica interanual não oferece ganho preditivo ou explicativo relevante em comparação com as variáveis biológicas principais (*Sexo* e *Espécie*), a desconsideração da variável temporal *Ano* não contribuirá para perda significativa de informação.

Avaliando correlações existentes

```
library(ggcorrplot)


num_cols <- c('bill_length_mm', 'bill_depth_mm', 'flipper_length_mm', 'body_mass_g')
matriz_corr <- cor(dados[num_cols], use = "complete.obs")

ggcorrplot(matriz_corr,
            lab = TRUE,
            lab_size = 4,
            colors = c("#4575b4", "white", "#d72522"),
```

```

outline.color = "white",
title = "Figura 4: Matriz de Correlação",
ggtheme = theme_minimal()) +
theme(
  plot.title = element_text(size = 12, face = "bold", hjust = 0.5)
)

```



(CITAR BODY_MASS e BILL_LENGTH como variáveis explicativas mais promissoras)

```


paleta_especies <- c('#4C72B0', '#DD8452', '#55A868')

GGally::ggpairs(
  dados,
  columns = num_cols,

  mapping = aes(color = species, fill = species, alpha = 0.7),
  # UpperSide são os valores de correlação
  upper = list(continuous = GGally::wrap("cor", size = 3.5)),
  # Diagonal são os gráficos de distribuição
  diag = list(continuous = GGally::wrap("densityDiag", alpha = 0.35)),
  # Lowerside são os pontos plottados
  lower = list(continuous = GGally::wrap("points", alpha = 0.5, size = 1.2))
) +
  scale_color_manual(values = paleta_especies) +
  scale_fill_manual(values = paleta_especies) +

```

```
theme_bw(base_size = 10) +
theme(
  strip.text = element_text(face = "bold", size = 9)
)
```



Pela separação de espécies, fica clara a forte e positiva correlação entre a massa corporal do pinguim e o tamanho de sua nadadeira, isso para todas as três espécies avaliadas. Ademais, vê-se uma extensão da similaridade antes comprovada nos boxplots que as espécies *Adelia* e *Chinstrap* compartilham de características intrínsecas para tamanho da nadadeira e profundidade do bico

```
p_agregado <- ggplot(dados, aes(flipper_length_mm, body_mass_g)) +
  geom_point(color = "#397E9E", alpha = 0.65) +
  geom_smooth(method = "lm", se = TRUE, color = "#00395C", fill = "#B5E5FF") +
  labs(
    title = "Relação agregada",
    subtitle = "Uma única reta para todos os pinguins",
    x = "Comprimento da nadadeira (mm)", y = "Massa corporal (g)"
  )
```

p_agregado

Relação agregada

Uma única reta para todos os pinguins

