



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Disciplina: Estatística Aplicada – Período: 2026.1

Professores: Profa. Dra. Amanda Gomes; Prof. Dr. Jerfson Bruno; Prof. Dr. Gilberto Matos

Modelagem da Relação entre Características Morfológicas de Pinguins

João Vítor Neves, Darlan Almeida, Emerson Sulpino

Departamento de Ciência da Computação - UFCG

Resumo Este trabalho aplica a metodologia de regressão linear múltipla (MRLM) ao conjunto de dados *Palmer Penguins*, proveniente do programa de Pesquisa Ecológica de Longo Prazo (LTER) na Antártica Ocidental, com o objetivo de modelar o tamanho da nadadeira a partir das demais variáveis morfológicas e ecológicas a partir das espécies *Adelie*, *Chinstrap* e *Gentoo*. Realizamos uma análise exploratória, incluindo correlações, box-plots e verificação de dados ausentes, ajustamos um modelo inicial com todas as variáveis explicativas disponíveis e identificamos multicolinearidade entre a massa corporal e a espécie. Seleccionamos então um modelo final por meio (CITAR O CRITÉRIO), livre de multicolinearidade relevante, e verificamos seus pressupostos através de análise de resíduos. Por fim, para dois conjuntos de valores das variáveis explicativas, apresentamos os intervalos de confiança para o valor médio esperado da variável resposta e os intervalos de predição para novas observações, com interpretação prática de ambos.

Palavras-Chave: regressao linear multipla, multicolinearidade, selecao de modelos, palmer penguins, analise exploratoria, caracteristicas morfometricas

1. Introdução

[text]

Variável resposta:

Usaremos `flipper_length_mm` — o comprimento da nadadeira, em milímetros — como resposta. Queremos investigar e prever essa medida partir das demais informações disponíveis sobre o pinguim: espécie, ilha, medidas do bico, massa corporal, sexo e ano de coleta.

Pergunta formulada:

Entre pinguins semelhantes nas demais características consideradas, como o comprimento esperado da nadadeira varia com cada preditor, e quão bem o modelo prevê novos pinguins?

Análise Exploratória

```
## species island bill_length_mm bill_depth_mm flipper_length_mm body_mass_g
## 1 Adelie Torgersen 39.1 18.7 181 3750
## 2 Adelie Torgersen 39.5 17.4 186 3800
## 3 Adelie Torgersen 40.3 18.0 195 3250
## 4 Adelie Torgersen NA NA NA NA
## 5 Adelie Torgersen 36.7 19.3 193 3450
## sex year
## 1 male 2007
## 2 female 2007
## 3 female 2007
## 4 <NA> 2007
## 5 female 2007
```

```
## species island bill_length_mm bill_depth_mm
## Length :344 Length :344 Min. :32.10 Min. :13.10
## N.unique : 3 N.unique : 3 1st Qu.:39.23 1st Qu.:15.60
## N.blank : 0 N.blank : 0 Median :44.45 Median :17.30
## Min.nchar: 6 Min.nchar: 5 Mean :43.92 Mean :17.15
## Max.nchar: 9 Max.nchar: 9 3rd Qu.:48.50 3rd Qu.:18.70
## Max. :59.60 Max. :21.50
## NAs :2 NAs :2
## flipper_length_mm body_mass_g sex year
## Min. :172.0 Min. :2700 Length :344 Min. :2007
## 1st Qu.:190.0 1st Qu.:3550 N.unique : 2 1st Qu.:2007
## Median :197.0 Median :4050 N.blank : 0 Median :2008
## Mean :200.9 Mean :4202 Min.nchar: 4 Mean :2008
## 3rd Qu.:213.0 3rd Qu.:4750 Max.nchar: 6 3rd Qu.:2009
## Max. :231.0 Max. :6300 NAs : 11 Max. :2009
## NAs :2 NAs :2
```

Figura 1: Contagem de Indivíduos pelas Variáveis Qualitativas





Figura 2: Distribuição das Variáveis Numéricas por Espécie

Boxplots sobrepostos com dispersão de indivíduos



Os diagramas de caixa (boxplots) confirmam a consistência das distribuições morfométricas na amostra. As caixas interquartílicas evidenciam a amplitude do centro dos dados para cada medida física. Nota-se a semelhante distribuição, entre as espécies *Adelie* e *Chinstrap*, para características como massa corporal, tamanho da nadadeira, e profundidade do bico que pode ser explicada pela (CITAR PONTO ECOLOGICO E MORFOLOGICO). Por outro lado, a espécie *Gentoo* se distingue ...

Tratamento de dados

Percebe-se que, na Figura 1, possuímos uma parcela de espécimes que não possuem seu sexo identificado. Com isso, avaliaremos o nível de importância dessa variável afim de tomar uma decisão quanto à remoção dos espécimes com informações faltantes ou à inclusão desses espécimes ao modelo

Considerando as seguintes hipóteses : $H_0 : \mu_{male} = \mu_{female}$ $H_1 : \mu_{male} \neq \mu_{female}$

Ao realizarmos um teste t de Student entre para a variável descrita, rejeitamos a hipótese nula de igualdade entre as médias, por termos obtido $t = 4,801$ e $p < 0,001$. Há evidências suficientes que indicam uma associação entre o sexo e o tamanho da nadadeira.

Ao realizarmos a aplicação do Coeficiente de Cohen, demonstramos que a variável *sexo* possui alta relevância preditiva e explicativa em relação ao comprimento da nadadeira, o que inviabiliza a exclusão da coluna inteira do conjunto de dados.


A variável apresentou 11 registros ausentes (NaN), o que corresponde a aproximadamente 3,2% da base total. Na literatura de análise de dados, proporções de dados faltantes inferiores a 5% são frequentemente tratadas através da exclusão das observações, já que a perda de poder estatístico é negligenciável.

Além disso, optou-se por não aplicar técnicas de imputação para inferir o sexo desses 11 espécimes. Como as características morfológicas possuem forte correlação com o sexo, deduzir essa categoria a partir de outras variáveis introduziria um viés de circularidade, inflando artificialmente as correlações na etapa de modelagem. Portanto, visando preservar a integridade da distribuição original e a confiabilidade das inferências estatísticas, as 11 tuplas contendo valores ausentes foram removidas, mantendo-se a coluna em sua totalidade para as etapas subsequentes.

Por fim, iremos fazer uma filtragem de uma das variáveis explicativas presente na base de dados. A variável em questão, não contribui com a explicabilidade da variável resposta: tamanho da nadadeira, visto que


Figura 3: Estabilidade Temporal do Comprimento da Nadadeira

A distribuição da variável resposta permanece constante ao longo dos anos




Embora o gráfico revele uma sutil variação negativa na mediana do ano de 2007 e uma assimetria na distribuição dos anos subsequentes (com maior concentração de pontos entre o terceiro e quarto quartis), essas nuances visuais não justificam a utilização dessa variável no modelo. A concentração assimétrica na porção superior das caixas reflete, na verdade, uma distribuição bimodal causada pela sobreposição das diferentes espécies na amostra anual, especificamente a presença da espécie Gentoo, cujos espécimes possuem dimensões naturalmente maiores. Dado que essa variação milimétrica interanual não oferece ganho preditivo ou explicativo relevante em comparação com as variáveis biológicas principais (*Sexo* e *Espécie*), a desconsideração da variável temporal *Ano* não contribuirá para perda significativa de informação.

Avaliando correlações existentes



(CITAR BODY_MASS e BILL_LENGTH como variáveis explicativas mais promissoras)



Pela separação de espécies, fica clara a forte e positiva correlação entre a massa corporal do pinguim e o tamanho de sua nadadeira, isso para todas as três espécies avaliadas. Ademais, vê-se uma extensão da similaridade antes comprovada nos boxplots que as espécies *Adelie* e *Chinstrap* compartilham de características intrínsecas para tamanho da nadadeira e profundidade do bico

Relação agregada

Uma única reta para todos os pinguins

