



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Disciplina: Estatística Aplicada – Período: 2026.1

Professores: Profa. Dra. Amanda Gomes; Prof. Dr. Jerfson Bruno; Prof. Dr. Gilberto Matos

Modelagem da Relação entre Características Morfológicas de Pinguins

João Vítor Neves, Darlan Almeida, Emerson Sulpino

Departamento de Ciência da Computação - UFCG

Resumo Este trabalho aplica a metodologia de regressão linear múltipla (MRLM) ao conjunto de dados *Palmer Penguins*, proveniente do programa de Pesquisa Ecológica de Longo Prazo (LTER) na Antártica Ocidental, com o objetivo de modelar o tamanho da nadadeira a partir das demais variáveis morfológicas e ecológicas a partir das espécies *Adelie*, *Chinstrap* e *Gentoo*. Realizamos uma análise exploratória, incluindo correlações, box-plots e verificação de dados ausentes, ajustamos um modelo inicial com todas as variáveis explicativas disponíveis e identificamos multicolinearidade entre a massa corporal e a espécie. Seleccionamos então um modelo final por meio (CITAR O CRITÉRIO), livre de multicolinearidade relevante, e verificamos seus pressupostos através de análise de resíduos. Por fim, para dois conjuntos de valores das variáveis explicativas, apresentamos os intervalos de confiança para o valor médio esperado da variável resposta e os intervalos de predição para novas observações, com interpretação prática de ambos.

Palavras-Chave: regressao linear multipla, multicolinearidade, selecao de modelos, palmer penguins, analise exploratoria, caracteristicas morfometricas

1. Introdução

[text]

Variável resposta:

Usaremos `flipper_length_mm` — o comprimento da nadadeira, em milímetros — como resposta. Queremos investigar e prever essa medida partir das demais informações disponíveis sobre o pinguim: espécie, ilha, medidas do bico, massa corporal, sexo e ano de coleta.

Pergunta formulada:

Entre pinguins semelhantes nas demais características consideradas, como o comprimento esperado da nadadeira varia com cada preditor, e quão bem o modelo prevê novos pinguins?

Setup

Iniciando a importação da base de dados

```
dados <- read.csv("06_Pinguins_comprimento_nadadeira.csv")
```

```
head(dados, n = 8)
```

```
##   species   island bill_length_mm bill_depth_mm flipper_length_mm body_mass_g
## 1 Adelie Torgersen      39.1         18.7          181          3750
## 2 Adelie Torgersen      39.5         17.4          186          3800
## 3 Adelie Torgersen      40.3         18.0          195          3250
## 4 Adelie Torgersen      NA           NA           NA           NA
## 5 Adelie Torgersen      36.7         19.3          193          3450
## 6 Adelie Torgersen      39.3         20.6          190          3650
## 7 Adelie Torgersen      38.9         17.8          181          3625
## 8 Adelie Torgersen      39.2         19.6          195          4675
##      sex year
## 1  male 2007
## 2 female 2007
## 3 female 2007
## 4  <NA> 2007
## 5 female 2007
## 6  male 2007
## 7 female 2007
## 8  male 2007
```

```
summary(dados)
```

```
##      species      island  bill_length_mm  bill_depth_mm
## Length  :344  Length  :344  Min.    :32.10  Min.    :13.10
## N.unique : 3   N.unique : 3   1st Qu.:39.23  1st Qu.:15.60
## N.blank  : 0   N.blank  : 0   Median :44.45  Median :17.30
## Min.nchar: 6   Min.nchar: 5   Mean    :43.92  Mean    :17.15
## Max.nchar: 9   Max.nchar: 9   3rd Qu.:48.50  3rd Qu.:18.70
##                                     Max.    :59.60  Max.    :21.50
##                                     NAs     :2      NAs     :2
```

```
## flipper_length_mm  body_mass_g          sex          year
## Min.      :172.0    Min.      :2700    Length   :344    Min.      :2007
## 1st Qu.:190.0    1st Qu.:3550    N.unique  : 2    1st Qu.:2007
## Median :197.0    Median :4050    N.blank   : 0    Median :2008
## Mean    :200.9    Mean    :4202    Min.nchar : 4    Mean    :2008
## 3rd Qu.:213.0    3rd Qu.:4750    Max.nchar : 6    3rd Qu.:2009
## Max.    :231.0    Max.    :6300    NAs       : 11    Max.    :2009
## NAs     :2        NAs     :2
```

Agora com a importação feita, vamos fazer uma avaliação inicial, buscando conhecer essa base de dados

Apresentação de variáveis

```
library(ggplot2)
library(patchwork)

cat_cols <- c('species', 'island', 'sex')
titulos <- c('Espécie', 'Ilha', 'Sexo')
paletas <- c('Blues', 'Oranges', 'Greens')

graficos <- lapply(1:3, function(i) {

  ggplot(dados, aes(x = .data[[cat_cols[i]]], fill = .data[[cat_cols[i]]])) +
    geom_bar() +
    geom_text(stat = "count", aes(label = after_stat(count)),
              vjust = -0.05, fontface = "bold", size = 4) +

    scale_fill_brewer(palette = paletas[i], direction = -1) +


    labs(title = paste('Distribuição por', titulos[i]),
         x = NULL,
         y = 'Frequência (n)') +

    theme_minimal() +
    theme(
      plot.title = element_text(size = 12, face = "bold"),
      legend.position = "none",
      plot.margin = margin(t = 10, unit="pt")
    )
})

grafico_final <- (graficos[[1]] | graficos[[2]] | graficos[[3]]) +
  plot_annotation(
    title = 'Contagem de Indivíduos pelas Variáveis Qualitativas',
    theme = theme(plot.title = element_text(size = 14, face = "bold", hjust = 0.5),
                  plot.margin = margin(t=10,b=-10, unit="pt")),
  )

grafico_final
```

Contagem de Indivíduos pelas Variáveis Qualitativas



```
library(tidyr)
library(ggplot2)
paleta_especies <- c('#4C72B0', '#DD8452', '#55A868')

# 1. Transformando os dados para o formato longo (Pivot)
dados_longos <- dados |>
  pivot_longer(
    # Usando as colunas reais do seu dataset de pinguins
    cols = c(bill_length_mm, bill_depth_mm, flipper_length_mm, body_mass_g),
    names_to = "medida",
    values_to = "valor"
  )

# 2. Gerando o gráfico facetado
ggplot(dados_longos, aes(x = species, y = valor, color = species)) +

  # Boxplot transparente para ver os pontos por trás
  geom_boxplot(aes(fill = species), alpha = 0.12, width = 0.58,
               outlier.shape = NA, linewidth = 0.55) +

  # Adiciona os pontos reais (Jitter) para mostrar o volume de dados
  geom_jitter(width = 0.14, alpha = 0.55, size = 1.35) +

  # Cria um quadro para cada "medida" automaticamente em 2 colunas
  facet_wrap(~ medida, scales = "free_y", ncol = 2) +
```

```

# Aplica a sua paleta de cores customizada
scale_color_manual(values = paleta_especies) +
scale_fill_manual(values = paleta_especies) +

# Rótulos (Adaptados para o seu contexto)
labs(
  title = "Distribuição das Variáveis Numéricas por Espécie",
  subtitle = "Boxplots sobrepostos com dispersão de indivíduos",
  x = NULL,
  y = "Valor",
  color = "Espécie"
) +

# Estilização herdada do seu código anterior + ajustes para os facets
theme_minimal() +
theme(
  # Centraliza e formata os títulos
  plot.title = element_text(size = 14, face = "bold", hjust = 0.5),
  plot.subtitle = element_text(size = 11, hjust = 0.5, color = "grey40"),

  # Coloca os títulos de cada sub-gráfico em negrito (bill_length, etc)
  strip.text = element_text(face = "bold", size = 11),

  # Remove as linhas de grade menores para um visual mais limpo
  panel.grid.minor = element_blank(),


  # Move a legenda para a parte inferior para dar mais espaço aos gráficos
  legend.position = "bottom"
) +

# Remove a legenda de preenchimento, pois a de contorno (color) já é suficiente
guides(fill = "none")

```

Distribuição das Variáveis Numéricas por Espécie

Boxplots sobrepostos com dispersão de indivíduos



Os diagramas de caixa (boxplots) confirmam a consistência das distribuições morfométricas na amostra. As caixas interquartílicas evidenciam a amplitude do centro dos dados para cada medida física. Nota-se a semelhante distribuição entre as espécies *Adelie* e *Chinstrap*,

Limpeza dos dados nulos, sendo justificados pelo teste de hipótese

- Percebe-se, pela plottagem de variáveis qualitativas, que possuímos uma parcela de espécimes que não possuem seu sexo identificado, assim, vamos avaliar a necessidade de sua possível remoção

Buscando entender possíveis correlações

```
library(ggcorrplot)


num_cols <- c('bill_length_mm', 'bill_depth_mm', 'flipper_length_mm', 'body_mass_g')
matriz_corr <- cor(dados[num_cols], use = "complete.obs")

ggcorrplot(matriz_corr,
            lab = TRUE,
```

```

lab_size = 4,
colors = c("#4575b4", "white", "#d72522"),
outline.color = "white",
title = "Matriz de Correlação",
ggtheme = theme_minimal()) +
theme(
  plot.title = element_text(size = 12, face = "bold", hjust = 0.5)
)

```



```


paleta_especies <- c('#4C72B0', '#DD8452', '#55A868')

GGally::ggpairs(
  dados,
  columns = num_cols,

  mapping = aes(color = species, fill = species, alpha = 0.7),
  # UpperSide são os valores de correlação
  upper = list(continuous = GGally::wrap("cor", size = 3.5)),
  # Diagonal são os gráficos de distribuição
  diag = list(continuous = GGally::wrap("densityDiag", alpha = 0.35)),
  # LowerSide são os pontos plottados
  lower = list(continuous = GGally::wrap("points", alpha = 0.5, size = 1.2))
) +
  scale_color_manual(values = paleta_especies) +
  scale_fill_manual(values = paleta_especies) +

```

```
theme_bw(base_size = 10) +
theme(
  strip.text = element_text(face = "bold", size = 9)
)
```



Pela separação de espécies, fica clara a forte e positiva correlação entre a massa corporal do pinguim e o tamanho de sua nadadeira, isso para todas as três espécies avaliadas. Ademais, vê-se uma extensão da similaridade antes comprovada nos boxplots que as espécies *Adelie* e *Chinstrap* compartilham de características intrínsecas para tamanho da nadadeira e profundidade do bico

```
p_agregado <- ggplot(dados, aes(flipper_length_mm, body_mass_g)) +
  geom_point(color = "#397E9E", alpha = 0.65) +
  geom_smooth(method = "lm", se = TRUE, color = "#00395C", fill = "#B5E5FF") +
  labs(
    title = "Relação agregada",
    subtitle = "Uma única reta para todos os pinguins",
    x = "Comprimento da nadadeira (mm)", y = "Massa corporal (g)"
  )
p_agregado
```


Relação agregada

Uma única reta para todos os pinguins

