



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Disciplina: Estatística Aplicada – Período: 2026.1

Professores: Profa. Dra. Amanda Gomes; Prof. Dr. Jerfson Bruno; Prof. Dr. Gilberto Matos

Modelagem do Comprimento da Nadadeira em Pinguins Antárticos

João Vítor Neves, Darlan Almeida, Emerson Sulpino

Departamento de Ciência da Computação - UFCG

Resumo Este trabalho aplica a metodologia de regressão linear múltipla (MRLM) ao conjunto de dados *Palmer Penguins*, proveniente do programa de Pesquisa Ecológica de Longo Prazo (LTER) na Antártica Ocidental, com o objetivo de modelar o comprimento da nadadeira de pinguins das espécies *Adelie*, *Chinstrap* e *Gentoo* a partir de variáveis morfológicas e categóricas. Realizou-se uma análise exploratória das distribuições, correlações e dados ausentes, seguida da combinação de diferentes subconjuntos de preditores avaliados por validação cruzada K-fold. O subconjunto com o menor RMSE médio (espécie, comprimento e profundidade do bico e massa corporal) apresentou colinearidade severa ($VIF > 10$) associada à espécie *Gentoo*, o que motivou seu descarte em favor de um modelo alternativo, sem diferença de desempenho preditivo estatisticamente detectável (teste t pareado com correção de Nadeau-Bengio, $p = 0,14$) e livre de multicolinearidade: o modelo composto exclusivamente pelas variáveis qualitativas espécie, ilha e sexo. Esse modelo, adotado como versão final, apresentou R^2 ajustado de 0,835, resíduos aproximadamente normais e desempenho preditivo sem diferença detectável em relação ao modelo mais complexo, evidenciando que o equilíbrio entre desempenho preditivo, parcimônia e ausência de colinearidade é o critério mais adequado para a seleção final, e não a validação cruzada isoladamente.

Palavras-Chave: regressão linear múltipla, multicolinearidade, seleção de modelos, palmer penguins, análise exploratória, características morfométricas

Contents

Modelagem do Comprimento da Nadadeira em Pinguins Antárticos	1
1. Introdução	3
Objetivos da análise	3
Variável resposta:	3
2. Descrição da base	3
3. Metodologia	4
4. Análise Exploratória	4
4.1 Distribuição das variáveis	4
4.2 Tratamento de dados	6
4.3 Avaliação de correlação entre variáveis	8
5. Seleção de Variáveis e Regressão dos modelos	9
5.1 Combinação de Variáveis e Validação Cruzada	10
5.2 Diagnóstico de Multicolinearidade do Candidato de Menor RMSE	10
5.3 Seleção do Modelo Final	10
5.4 Modelo Final: Estimativas dos Coeficientes	11
6. Análise de Resíduos	13
7. Previsão e Incerteza	14
8. Conclusões	15
Referências	15

1. Introdução

Este trabalho utiliza o conjunto de dados *Palmer Penguins*, coletado pelo programa de Pesquisa Ecológica de Longo Prazo (LTER) entre 2007 e 2009, para investigar quais características morfológicas e categóricas explicam o comprimento da nadadeira dos indivíduos amostrados. Diferentemente de uma descrição puramente correlacional, buscamos um modelo de regressão linear múltipla (MRLM) que permita interpretar efeitos parciais — isto é, o efeito de cada variável mantendo as demais constantes —, avaliar a adequação de suas suposições e quantificar a incerteza tanto para o valor médio esperado da resposta quanto para novas observações individuais. A validação cruzada K-fold foi empregada como ferramenta de comparação de desempenho preditivo entre subconjuntos de variáveis candidatas, e não como critério único e automático de seleção do modelo final.

Objetivos da análise

- Caracterizar exploratoriamente as variáveis morfológicas e categóricas disponíveis;
- Ajustar um modelo inicial com todas as variáveis explicativas e avaliar multicolinearidade;
- Aplicar validação cruzada K-fold como ferramenta de comparação de desempenho preditivo entre subconjuntos de variáveis candidatas, e não como critério único e automático de seleção do modelo final;
- Selecionar, entre modelos candidatas, aquele com melhor equilíbrio entre desempenho preditivo, parcimônia e colinearidade controlada dentro de limites aceitáveis;
- Verificar as suposições do MRLM por meio de diagnóstico de resíduos;
- Construir intervalos de confiança e de predição para cenários específicos, com interpretação prática.

Variável resposta:

Usaremos `comprimento_nadadeira_mm` — o comprimento da nadadeira, em milímetros — como resposta. Queremos investigar e prever essa medida partir das demais informações disponíveis sobre o pinguim: espécie, ilha, medidas do bico, massa corporal, sexo e ano de coleta.

Pergunta formulada:

Entre pinguins semelhantes nas demais características consideradas, como o comprimento esperado da nadadeira varia com cada preditor?

2. Descrição da base

A base de dados Palmer Penguins possui $n = 344$ espécimes registrados, coletados no arquipélago Palmer, na Antártica Ocidental, entre 2007 e 2009. A unidade de análise é o indivíduo, e a base reúne 8 variáveis morfológicas, categóricas e temporais, descritas na Tabela 1.

Table 1: Dicionário de variáveis

Variável	Tipo	Papel	Definição	Unidade
especie	Categórica	Preditor	Espécie do pinguim (Adelie, Chinstrap, Gentoo)	-
ilha	Categórica	Preditor	Ilha de observação (Dream, Torgersen, Biscoe)	-
comprimento_bico_mm	Numérica	Preditor	Comprimento do bico	milímetros
profundidade_bico_mm	Numérica	Preditor	Profundidade do bico	milímetros
comprimento_nadadeira_mm	Numérica	Resposta	Comprimento da nadadeira	milímetros
massa_corporal_g	Numérica	Preditor	Massa corporal	gramas
sexo	Categórica	Preditor	Sexo do pinguim (macho, fêmea)	-
ano	Inteira	Descartada	Ano em que a observação foi registrada	-

A qualidade da base foi avaliada antes de qualquer modelagem: 11 registros (3,2%) não possuem sexo identificado. Desses 11, 2 registros também não possuem nenhuma das medidas morfológicas — permanecendo disponíveis, nesses casos específicos, apenas espécie, ilha e ano. Ou seja, o total de registros com ao menos uma informação relevante ausente é 11 (não 13, já que os 2 casos mais incompletos estão contidos nesse mesmo grupo de 11). O tratamento dado a esses casos, assim como a decisão sobre a variável *ano*, é discutido em detalhe na Seção 4.2, dentro da análise exploratória.

3. Metodologia

A análise foi estruturada em cinco etapas principais que contém exame das distribuições univariadas e bivariadas das variáveis morfológicas e categóricas, tratamento dos dados ausentes (variáveis sexo e ano) e avaliação da correlação entre os preditores contínuos e a resposta. A partir do modelo completo (Seção 5), todos os subconjuntos possíveis de grupos de preditores (espécie, ilha, sexo, comprimento do bico, profundidade do bico, massa corporal) foram avaliados por validação cruzada K-fold ($k = 5$), utilizando o RMSE médio como métrica principal de desempenho preditivo (Seção 5.1).

Os subconjuntos com melhor desempenho foram comparados entre si por meio do teste t pareado com correção de variância de Nadeau-Bengio, que ajusta a variância estimada para compensar a dependência entre as dobras de treino e teste, controlando a inflação de falsos positivos característica da validação cruzada k-fold (Nadeau & Bengio, 2003) — problema já apontado por Dietterich (1998) ao discutir os riscos de testes estatísticos ingênuos na comparação de algoritmos de aprendizado avaliados por reamostragem (Seção 5.1). O subconjunto de menor RMSE médio foi diagnosticado quanto à multicolinearidade pelo Fator de Inflação da Variância (VIF), definido como $VIF_j = 1/(1-R^2)$, em que R^2 é o coeficiente de determinação da regressão de X_j sobre as demais explicativas; valores de $VIF > 10$ foram tratados como indicativo de multicolinearidade severa. Constatada colinearidade severa nesse subconjunto (Seção 5.2), a seleção final priorizou, entre os candidatos sem diferença de desempenho detectável, o modelo livre desse problema e com coeficientes mais diretamente interpretáveis — e não apenas o de menor RMSE (Seção 5.3).

A validação do modelo final ancorou-se na verificação gráfica e formal dos pressupostos clássicos dos resíduos (Seção 6): - Linearidade e Homocedasticidade: diagrama de resíduos versus valores ajustados e Teste de Breusch-Pagan (H_0 : variância constante); - Normalidade dos Erros: gráfico Q-Q Plot e teste formal de Jarque-Bera (H_0 : distribuição normal dos erros); - Independência dos Erros: Teste de Durbin-Watson (H_0 : ausência de autocorrelação nos resíduos). Por fim, construíram-se intervalos de confiança (IC) para a média e intervalos de predição (IP) para observações individuais em cenários hipotéticos representativos de cada espécie (Seção 7).

4. Análise Exploratória

4.1 Distribuição das variáveis

Antes de investigar as relações entre as variáveis, examinamos a distribuição individual de cada uma. A Figura 1 apresenta a contagem de indivíduos segundo espécie, ilha e sexo, permitindo avaliar o grau de balanceamento das categorias na amostra.





Figure 1: Distribuição de variáveis qualitativas

A espécie *Adelle* é a mais representativa da amostra (152 indivíduos; 44,2%), seguida por *Gentoo* (124; 36,0%) e *Chinstrap* (68; 19,8%). Geograficamente, *Biscoe* concentra quase metade dos registros (168; 48,8%), seguida por *Dream* (124; 36,0%) e *Torgersen* (52; 15,1%). O sexo está quase perfeitamente balanceado entre os indivíduos identificados (165 fêmeas, 168 machos), restando 11 sem identificação.

Em seguida, avaliamos a distribuição das variáveis morfométricas contínuas por espécie, de modo a identificar diferenças de escala e possíveis padrões de sobreposição entre grupos, conforme apresentado na Figura 2.



Fonte: Elaborado pelo autor (2026).

Figure 2: Distribuição de variáveis quantitativas

Os diagramas de caixa, da Figura 2, confirmam a consistência das distribuições morfométricas na amostra. Nota-se a semelhante distribuição, entre as espécies *Adelie* e *Chinstrap*, para características como massa corporal, tamanho da nadadeira e profundidade do bico, fato que pode ser explicado pela **convergência ecomorfológica e sobreposição parcial de nicho trófico entre ambas as espécies**, que compartilham hábitos de forrageamento de menor profundidade em relação aos *Gentoo*. Por outro lado, a espécie *Gentoo* se distingue acentuadamente por apresentar maior massa corporal e nadadeiras significativamente mais longas (gigantismo relativo dentro do gênero), porém acompanhadas por bicos proporcionalmente mais rasos (*profundidade_bico_mm*).

4.2 Tratamento de dados

4.2.1 Variável Sexo A análise inicial da variável sexo revelou a presença de 11 registros ausentes (NaN), perceptível na Figura 1, o que corresponde a aproximadamente 3,2% da base total. Como proporções de dados faltantes inferiores a 5% são consideradas irrisórias na literatura de análise de dados, acarretando perda negligenciável de poder estatístico, optou-se pela exclusão direta desses indivíduos do conjunto de dados. Alternativas como a imputação múltipla (Schafer, 1999) poderiam preservar essas observações para a modelagem, mas foram descartadas neste trabalho dada a baixa proporção de dados ausentes frente ao ganho marginal esperado e à preferência por manter a simplicidade e a transparência do tratamento de dados.

Considerando as seguintes hipóteses:

$$H_0 : \mu_{\text{macho}} = \mu_{\text{femea}} \quad H_1 : \mu_{\text{macho}} \neq \mu_{\text{femea}}$$

A aplicação do teste *t* de Student rejeitou a hipótese nula de igualdade entre as médias ($t = 4,801$; $p < 0,001$), fornecendo fortes evidências de associação entre o sexo e o tamanho da nadadeira. Complementarmente, o

cálculo do Coeficiente de Cohen, que resultou em ($d = 0,526$), classificado como um efeito de magnitude moderada segundo os limiares convencionais (pequeno 0,2; moderado 0,5; grande 0,8) propostos por Cohen (1988). Dessa forma, entende-se que a variável possui alta relevância explicativa e tamanho de efeito considerável, cuja exclusão deve se restringir estritamente às linhas com informações ausentes, enquanto a variável sexo justifica plenamente sua inclusão na formulação do modelo completo inicial.

4.2.2 Variável Ano Antes de decidir sobre a inclusão da variável *ano* na modelagem, verificamos visualmente sua relação com a resposta. A Figura 3 mostra a distribuição do comprimento da nadadeira segundo o ano de coleta.




Figure 3: Distribuição do tamanho da nadadeira por Ano

Diferentemente do que uma inspeção apenas visual da Figura 3 poderia sugerir, o ano de coleta não é estatisticamente irrelevante para a resposta: uma ANOVA de um fator ($\text{comprimento_nadadeira_mm} \sim \text{ano}$) rejeita a hipótese de médias iguais entre os três anos ($F = 5,41$; $p = 0,005$), e o efeito permanece altamente significativo mesmo controlando por espécie, ilha e sexo (teste F para a inclusão de *ano* no modelo qualitativo: $F = 25,68$; $p < 0,001$). Ainda assim, *ano* foi descartada da modelagem, por duas razões que se complementam. Primeiro, razão substantiva: a distribuição de espécies não é idêntica entre os anos (*Adelie*: 44/50/52; *Chinstrap*: 26/18/24; *Gentoo*: 33/45/41, em 2007/2008/2009), de modo que parte da associação entre *ano* e a resposta é herdada da composição amostral, e não de uma mudança biológica real ano a ano. Segundo, e mais decisivo: razão de generalização, pois em um cenário real de aplicação do modelo, os anos presentes na base de treinamento (2007/2009) não estarão mais disponíveis para observações futuras — um pinguim medido em 2026 teria um valor de *ano* fora do domínio observado, exigindo extrapolação categórica sem sustentação nos dados. Uma variável de calendário específica ao período de coleta não generaliza para novas coletas, ao contrário de espécie, ilha, sexo e medidas morfológicas, que são atributos válidos para qualquer pinguim amostrado no futuro. Por esse motivo, apesar de sua significância estatística nesta amostra, *ano* foi excluída de todos os modelos candidatos.

4.3 Avaliação de correlação entre variáveis

Para investigar a associação entre os preditores contínuos e a variável resposta, calculamos a matriz de correlação de Pearson, apresentada na Figura 4.





Figure 4: Mapa de calor entre variáveis

A Figura 4 apresenta a matriz de correlação de Pearson entre as variáveis numéricas contínuas. Observa-se uma forte correlação positiva entre o comprimento da nadadeira (`comprimento_nadadeira_mm`) e a massa corporal (`massa_corporal_g`) ($r = 0,87$), evidenciando que a massa é o principal preditor linear contínuo do tamanho do apêndice. O comprimento do bico (`comprimento_bico_mm`) também exibe correlação positiva considerável ($r = 0,65$) com a variável resposta. Em contrapartida, a profundidade do bico (`profundidade_bico_mm`) apresenta correlação negativa com a nadadeira ($r = -0,58$), um comportamento aparente causado pela presença da espécie *Gentoo*, cujos indivíduos possuem nadadeiras longas e bicos finos.

Para complementar a matriz de correlação e observar como essas associações se comportam dentro de cada espécie — em vez de apenas na amostra agregada —, geramos os gráficos de dispersão pareados a seguir, coloridos por espécie.



Fonte: Elaborado pelos autores (2026).

Pela separação de espécies, fica clara a forte e positiva correlação entre a massa corporal do pinguim e o tamanho de sua nadadeira, isso para todas as três espécies avaliadas. Essa constatação é central para a discussão de multicolinearidade na Seção 5.2: variáveis contínuas fortemente associadas à espécie tendem a ser redundantes com ela em um mesmo modelo. Ademais, vê-se uma extensão da similaridade antes comprovada nos diagramas de caixa que as espécies *Adelie* e *Chinstrap* compartilham de características intrínsecas para tamanho da nadadeira e profundidade do bico

5. Seleção de Variáveis e Regressão dos modelos

Com a base de dados tratada e as relações bivariadas delineadas na etapa exploratória, esta seção detalha o processo de seleção do modelo de regressão linear múltipla. O objetivo central é identificar o subconjunto de preditores que melhor explica o comprimento da nadadeira, priorizando o equilíbrio entre precisão preditiva, parcimônia e confiabilidade interpretativa. Para evitar a escolha de um modelo superajustado ou com coeficientes matematicamente instáveis, a estratégia de seleção foi fundamentada em três pilares analíticos: a minimização do erro de predição em dados não vistos (avaliada via validação cruzada *K-Fold*), a garantia de independência informacional entre os preditores (diagnosticada pelo Fator de Inflação da Variância - VIF) e a comparação formal de desempenho por testes de hipótese. A seguir, descreve-se o percurso metodológico que orientou o descarte de modelos concorrentes e a parametrização do modelo final.

5.1 Combinação de Variáveis e Validação Cruzada

Realizou-se uma busca exaustiva por combinações de grupos de variáveis (espécie, ilha, sexo, comprimento e profundidade do bico, massa corporal), avaliadas por validação cruzada K-Fold ($k = 5$), utilizando o RMSE médio como métrica principal. Para comparar os candidatos mais competitivos, aplicou-se o teste t pareado com a correção de variância de Nadeau-Bengio (*Nadeau & Bengio, 2003*), conforme apresentado na Tabela 2:

Table 2: Comparativo de Desempenho Preditivo entre Subconjuntos de Variáveis

Modelo	Variáveis Preditores	RMSE Médio (K-Fold)	R ² Ajustado
Candidato Multicolinear	Espécie, Bico (Compr. e Prof.), Massa	5.29 mm	0.861
Modelo A (Qualitativo)	Espécie, Ilha, sexo	5.77 mm	0.835
Modelo B (Quantitativo)	Bico (Compr. e Prof.), Massa	5.86 mm	0.830

5.2 Diagnóstico de Multicolinearidade do Candidato de Menor RMSE

O subconjunto de menor RMSE médio (espécie, comprimento e profundidade do bico e massa corporal) foi diagnosticado quanto à multicolinearidade pelo VIF antes de ser considerado modelo final, conforme mostra a Tabela 3.

Table 3: Fator de Inflação da Variância (VIF) do candidato de menor RMSE.

Variável	VIF
especie_Chinstrap	4.115
especie_Gentoo	14.654
comprimento_bico_mm	5.534
profundidade_bico_mm	5.449
massa_corporal_g	5.894

A indicadora referente à espécie *Gentoo* apresenta $VIF = 14,65$, ultrapassando o limiar de severidade ($VIF > 10$) definido na Seção 3.4. Esse resultado decorre da forte associação entre a espécie *Gentoo* e as variáveis *massa_corporal_g* e *profundidade_bico_mm*: indivíduos dessa espécie apresentam massa corporal média de 5.092g — cerca de 37% acima de *Adelie* (3.706g) e *Chinstrap* (3.733g) — e profundidade de bico média de 15,0mm, sensivelmente menor que os 18,3–18,4mm das outras duas espécies. Em outras palavras, saber que um pinguim é *Gentoo* já entrega grande parte da informação que *massa_corporal_g* e *profundidade_bico_mm* também carregam: é essa sobreposição de informação que o VIF detecta matematicamente.

Colinearidade severa não invalida o poder preditivo agregado do modelo, mas compromete a interpretação isolada de cada coeficiente — em particular, o efeito estimado da espécie *Gentoo*, misturado ao efeito da massa e da profundidade do bico, deixa de ser confiável para leitura individual. Diante disso, esse candidato não foi mantido como modelo final.

5.3 Seleção do Modelo Final

A decisão entre os candidatos não se apoiou apenas no RMSE médio, mas no conjunto de evidências reunidas nas Seções 5.1 e 5.2. Os três testes pareados relevantes indicam:

- Candidato Multicolinear vs. Modelo Qualitativo: sem diferença de desempenho estatisticamente detectável ($p = 0,14$);

- Modelo Qualitativo vs. Modelo Quantitativo: sem diferença de desempenho estatisticamente detectável ($p = 0,79$);
- Candidato Multicolinear vs. Modelo Quantitativo: diferença estatisticamente detectável ($p = 0,02$), favorecendo o candidato multicolinear.

Cabe uma ressalva metodológica: como os três testes foram conduzidos aos pares a partir do mesmo conjunto de candidatos, sem correção para comparações múltiplas, o p-valor de 0,02 deve ser interpretado com cautela — sob um ajuste conservador do tipo Bonferroni (limiar efetivo de $/3 = 0,017$ para manter $\alpha = 0,05$ global), essa diferença deixaria de ser considerada estatisticamente detectável. Ainda assim, o resultado que efetivamente orienta a decisão desta seção — a ausência de diferença detectável entre o Candidato Multicolinear e o Modelo Qualitativo ($p = 0,14$) — permanece válido sob qualquer correção razoável. É importante frisar, também, que a ausência de diferença estatisticamente detectável não constitui prova formal de equivalência entre os modelos: ela apenas indica que os dados disponíveis não oferecem evidência suficiente para distingui-los nesse aspecto específico.

Como o Candidato Multicolinear não supera o Modelo A (Qualitativo) de forma detectável, e apresenta colinearidade severa que o Modelo A não apresenta (VIF máximo de 3,17, ante 14,65), optou-se por descartar o candidato de menor RMSE bruto e adotar o Modelo Qualitativo — composto por espécie, ilha e sexo — como modelo final. Essa escolha equilibra três critérios: desempenho preditivo sem diferença detectável em relação ao melhor candidato, ausência de multicolinearidade relevante entre os preditores, e maior interpretabilidade dos coeficientes, já que nenhuma variável contínua se sobrepõe informacionalmente à espécie.

O Modelo Quantitativo, embora também livre de colinearidade, foi descartado por apresentar desempenho preditivo estatisticamente inferior ao candidato de menor RMSE ($p = 0,02$, ressalvada a cautela quanto a comparações múltiplas discutida acima) e por prescindir da variável espécie, cuja contribuição individual se mostrou relevante mesmo controlando pelas demais variáveis morfológicas e categóricas do modelo.

5.4 Modelo Final: Estimativas dos Coeficientes

A Tabela 4 apresenta as estimativas do modelo final, ajustado com todas as 333 observações após a limpeza (Seção 4.2). As variáveis categóricas foram codificadas segundo o esquema clássico de variáveis dummy (Suits, 1957), no qual uma categoria de cada grupo é definida como referência e absorvida pelo intercepto:

$$\text{flipper length mm} = \beta_0 + \beta_1 \cdot \text{chinstrap} + \beta_2 \cdot \text{gentoo} + \beta_3 \cdot \text{dream} + \beta_4 \cdot \text{torgersen} + \beta_5 \cdot \text{macho} + \varepsilon$$

Table 4: Estimativas dos coeficientes do modelo final (Modelo A).

Variável	Estimativa	Erro Padrão	Estatística t	Valor-p
Intercepto (Adelie, Biscoe, fêmea)	185.3651	0.9134	202.9368	< 0,001
Espécie: Chinstrap	5.9586	1.0327	5.7701	< 0,001
Espécie: Gentoo	28.3534	1.0047	28.2203	< 0,001
Ilha: Dream	1.0694	1.1517	0.9286	0,353804
Ilha: Torgersen	2.8094	1.1945	2.3520	0,019267
sexo: Macho	6.8606	0.6242	10.9912	< 0,001

O modelo final apresenta R^2 ajustado de 0,835, indicando que aproximadamente 83,5% da variabilidade observada no comprimento da nadadeira é explicada por espécie, ilha e sexo. Mantidas as demais variáveis constantes, ser *Gentoo* está associado a uma nadadeira, em média, 28,4mm mais longa que *Adelie*; ser *Chinstrap*, a uma nadadeira 6,0mm mais longa; e ser macho, a uma nadadeira 6,9mm mais longa que fêmea. O efeito da ilha é mais discreto: viver em *Torgersen* está associado a uma nadadeira 2,8mm mais longa que

Table 5: Medidas globais de ajuste do modelo vencedor.

Medida	Valor
R ² ajustado	0.835
AIC	2111.440
BIC	2138.090

em *Biscoe* ($p = 0,019$), enquanto o efeito de *Dream* não é estatisticamente distinguível de *Biscoe* ($p = 0,354$) — a variável foi mantida por seu efeito de conjunto (grupo ilha) e porque sua remoção isolada não é o objetivo desta seleção, feita por grupos de variáveis e não por preditor individual.

A Tabela 6 confirma a ausência de multicolinearidade relevante no modelo final.

Table 6: Fator de Inflação da Variância (VIF) do modelo final (Modelo A).

Variável	VIF
Espécie: Chinstrap	1.780
Espécie: Gentoo	2.381
Ilha: Dream	3.173
Ilha: Torgersen	1.776
sexo: Macho	1.000

Todos os VIFs do modelo final estão bem abaixo do limiar de severidade ($VIF > 10$), com máximo de 3,17 para ilha_Dream — confirmando a ausência de multicolinearidade relevante e reforçando a leitura individual dos coeficientes apresentados na Tabela 4.

6. Análise de Resíduos

A Figura 5 e a Tabela 7 avaliam formal e visualmente as suposições de média nula, homocedasticidade e normalidade, além de verificar a possível presença de pontos de alavancagem.




Figure 5: Gráficos de diagnóstico de resíduos

Table 7: Testes Formais de Diagnóstico dos Resíduos do Modelo Vencedor.

Teste Diagnóstico	Premissa Avaliada	Estatística	Valor-p
Breusch-Pagan	Homocedasticidade	13.0428	0,022981
Jarque-Bera	Normalidade	0.0506	0,975032
Durbin-Watson	Independência (Autocorr.)	1.7811	0,014784

A Figura 5 ilustra o diagnóstico de resíduos e a tabela 7 apresenta os resultados dos testes estatísticos formais aplicados aos resíduos do modelo selecionado. A análise indica que, ao nível de 5% de significância, houve rejeição das hipóteses nulas para as três premissas clássicas do modelo de Mínimos Quadrados Ordinários.

O diagnóstico dos resíduos do modelo final é sensivelmente melhor que o do candidato descartado na Seção 5.2. O teste de Jarque-Bera não rejeita a normalidade dos erros ($p = 0,975$), resultado consideravelmente mais

favorável do que o observado para o candidato multicolinear ($p = 0,0285$ no modelo original), o que é coerente com a substituição de preditores contínuos correlacionados por indicadoras categóricas bem separadas entre grupos. O teste de Durbin-Watson (1,78) situa-se próximo de 2, não indicando autocorrelação relevante nos resíduos. Persiste, porém, heterocedasticidade estatisticamente detectável pelo teste de Breusch-Pagan ($p = 0,023$): a variância dos resíduos não é totalmente constante ao longo dos valores ajustados. Como no candidato original, esse padrão é compatível com o contexto biológico — é esperado que espécimes de maior porte apresentem variabilidade natural superior à de espécimes menores — mas, diferentemente do observado antes, o p-valor é menos extremo, sugerindo heterocedasticidade mais moderada.

Na Figura 5 nota-se não apenas a assimetria de diferentes espécimes representados no gráfico, como a tendência da espécie maior *Gentoo* ser menos dispersa que as demais espécies *Adelie* e *Chinstrap*. A separação dos valores ajustados por espécie confirma que o modelo final discrimina corretamente os três grupos (*Adelie* e *Chinstrap* concentrados nos valores preditos mais baixos, *Gentoo* isolado nos valores mais altos), sem sobreposição relevante entre as nuvens de resíduos das diferentes espécies.

7. Previsão e Incerteza

Com o modelo vencedor, foram construídos três cenários representativos, correspondentes a um pinguim típico de cada espécie da base de dados. A Tabela 8 descreve as características morfológicas adotadas em cada cenário, e a Tabela 9 apresenta as estimativas do comprimento da nadadeira juntamente com seus respectivos intervalos de confiança (IC) e de predição (IP).

Table 8: Cenários hipotéticos utilizados na previsão.

Cenário	Espécie	Ilha	sexo
Pinguim A	Adelie	Dream	fêmea
Pinguim B	Chinstrap	Dream	fêmea
Pinguim C	Gentoo	Biscoe	macho

Table 9: Intervalos de confiança e de predição para o comprimento da nadadeira.

Cenário	Intervalo	Estimativa	Inferior	Superior
Pinguim A	IC 95% da média	186.43	184.80	188.07
Pinguim B	IC 95% da média	192.39	190.90	193.88
Pinguim C	IC 95% da média	220.58	219.39	221.77
Pinguim A	IP 95% individual	186.43	175.11	197.76
Pinguim B	IP 95% individual	192.39	181.09	203.69
Pinguim C	IP 95% individual	220.58	209.31	231.84

O intervalo de confiança (IC) captura a incerteza sobre o comprimento médio esperado de todos os pinguins com aquele conjunto de preditores; o intervalo de predição (IP) captura a incerteza para um único pinguim novo, incorporando também a variação residual do modelo — por isso é sempre mais amplo, e é o apropriado para estimar um indivíduo específico. Essa diferença aparece claramente nos três cenários: o IP tem entre 6 e 10 vezes a amplitude do IC correspondente (por exemplo, no Pinguim A, 22,65mm de amplitude contra apenas 3,27mm), refletindo que o IC responde apenas pela incerteza da média, enquanto o IP soma a ela a variabilidade individual não explicada pelo modelo. Os três cenários não se sobrepõem em nenhum dos dois tipos de intervalo, reforçando numericamente o que já havia sido observado nos boxplots da Seção 4.1 (Figura 2) e no gráfico de resíduos por espécie da Seção 6 (Figura 5): a espécie mantém forte poder discriminativo sobre o comprimento da nadadeira, mesmo em um modelo composto inteiramente por variáveis categóricas.

8. Conclusões

As variáveis morfológicas dos pinguins do arquipélago *Palmer* mostram-se fortemente associadas entre si e nitidamente agrupadas por espécie, refletindo distinções anatômicas claras de massa e estrutura de bico. A avaliação por validação cruzada K-fold indicou que o subconjunto de menor RMSE médio (espécie, medidas do bico e massa corporal) era, ao mesmo tempo, o de maior colinearidade ($VIF = 14,65$ para *Gentoo*) — evidência de que a menor métrica de erro, isoladamente, não é suficiente para escolher um modelo final.

Diante da ausência de diferença de desempenho estatisticamente detectável entre esse candidato e um modelo composto apenas por espécie, ilha e sexo (*teste t pareado com correção de Nadeau-Bengio*, $p = 0,14$; resultado que se mantém mesmo sob correção conservadora para comparações múltiplas), e da ausência de multicolinearidade relevante nesse segundo modelo (VIF máximo de 3,17), optou-se por adotá-lo como modelo final. Esse modelo, inteiramente qualitativo, preservou um bom poder explicativo (R^2 ajustado = 0,835) e apresentou diagnóstico de resíduos mais favorável que o candidato descartado, com normalidade dos erros não rejeitada pelo teste de Jarque-Bera ($p = 0,975$) e independência confirmada pelo teste de Durbin-Watson (1,78); persiste apenas heterocedasticidade moderada, detectada pelo teste de Breusch-Pagan ($p = 0,023$), compatível com a maior variabilidade natural esperada em espécimes de maior porte.

Essa heterocedasticidade residual é registrada aqui como a principal fragilidade metodológica do trabalho: tanto os erros-padrão dos coeficientes (Seção 5.4) quanto os intervalos de confiança e de predição (Seção 7) foram calculados sob a suposição clássica de variância constante dos erros, suposição que o próprio teste de Breusch-Pagan rejeita. Na prática, isso sugere que a incerteza reportada pode estar levemente subestimada para as espécies com resíduos mais dispersos (*Adelie* e *Chinstrap*) e levemente superestimada para *Gentoo*. Trabalhos futuros poderiam endereçar essa limitação com erros-padrão robustos (estimador de White/HC3) ou mínimos quadrados ponderados por grupo, sem alterar a conclusão qualitativa da seleção de variáveis aqui apresentada.

O tratamento da variável *ano* ilustra uma lógica semelhante de cautela na leitura da significância estatística: embora estatisticamente significativa nesta amostra (mesmo controlando por espécie, ilha e sexo), foi descartada por não representar um atributo generalizável — os anos de coleta observados não estarão disponíveis para novas observações futuras, tornando a variável útil apenas para descrever esta amostra específica, e não para prever novos pinguins.

O modelo final permite estimar o comprimento da nadadeira a partir da espécie, da ilha e do sexo do indivíduo, sem depender de medidas morfológicas contínuas redundantes entre si. Embora a heterocedasticidade residual exija cautela na leitura de intervalos de predição para observações muito distantes do centro da amostra, a robustez da comparação por validação cruzada, aliada ao diagnóstico de multicolinearidade e de resíduos, sustenta esse modelo como a escolha mais adequada entre desempenho preditivo, parcimônia e interpretabilidade para a inferência morfológica dentro do intervalo de medidas catalogadas nas ilhas do arquipélago.

Referências

- COHEN, J. Statistical Power Analysis for the Behavioral Sciences. 2. ed. Hillsdale, NJ: Lawrence Erlbaum Associates, 1988.
- DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. Neural Computation, v. 10, n. 7, p. 1895–1923, 1998.
- NADEAU, C.; BENGIO, Y. Inference for the generalization error. Machine Learning, v. 52, n. 3, p. 239–281, 2003.
- SCHAFER, J. L. Multiple imputation: a primer. Statistical Methods in Medical Research, v. 8, n. 1, p. 3–15, 1999.
- SUITS, D. B. Use of dummy variables in regression equations. Journal of the American Statistical Association, v. 52, n. 280, p. 548–551, 1957.