



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Disciplina: Estatística Aplicada – Período: 2026.1

Professores: Profa. Dra. Amanda Gomes; Prof. Dr. Jerfson Bruno; Prof. Dr. Gilberto Matos

---

## Modelagem da Relação entre Características Morfológicas de Pinguins

João Vítor Neves, Darlan Almeida, Emerson Sulpino

Departamento de Ciência da Computação - UFCG

---

**Resumo** Este trabalho aplica a metodologia de regressão linear múltipla (MRLM) ao conjunto de dados *Palmer Penguins*, proveniente do programa de Pesquisa Ecológica de Longo Prazo (LTER) na Antártica Ocidental, com o objetivo de modelar o comprimento da nadadeira de pinguins das espécies *Adelie*, *Chinstrap* e *Gentoo* a partir de variáveis morfológicas e categóricas. Realizou-se uma análise exploratória das distribuições, correlações e dados ausentes, seguida do ajuste de um modelo completo e da comparação de subconjuntos de preditores por validação cruzada *K-Fold*. O modelo selecionado, composto por espécie, comprimento do bico, profundidade do bico e massa corporal, apresentou o menor RMSE médio entre os candidatos avaliados. A comparação por teste *t* pareado com correção de Nadeau-Bengio reforçou a superioridade desse modelo em relação ao modelo apenas quantitativo, enquanto os diagnósticos indicaram boa capacidade explicativa, com presença de heterocedasticidade e leve afastamento da normalidade dos resíduos. Assim, o relatório preserva a seleção do modelo como uma decisão baseada no conjunto das evidências: desempenho preditivo, parcimônia, contribuição estatística da espécie e avaliação dos pressupostos.

**Palavras-Chave:** regressão linear múltipla, multicolinearidade, seleção de modelos, palmer penguins, análise exploratória, características morfométricas

---

### 1. Introdução

Este trabalho utiliza o conjunto de dados *Palmer Penguins*, coletado pelo programa de Pesquisa Ecológica de Longo Prazo (LTER) entre 2007 e 2009, para investigar quais características morfológicas e categóricas explicam o comprimento da nadadeira dos indivíduos amostrados. Diferentemente de uma descrição puramente correlacional, buscamos um modelo de regressão linear múltipla (MRLM) que permita interpretar efeitos parciais — isto é, o efeito de cada variável mantendo as demais constantes —, avaliar a adequação de suas suposições e quantificar a incerteza tanto para o valor médio esperado da resposta quanto para novas observações individuais.

## Objetivos da análise

- caracterizar exploratoriamente as variáveis morfológicas e categóricas disponíveis;
- ajustar um modelo inicial com todas as variáveis explicativas e avaliar multicolinearidade;
- selecionar, entre modelos candidatos, aquele com melhor equilíbrio entre desempenho preditivo, parcimônia e ausência de colinearidade relevante;
- verificar as suposições do MRLM por meio de diagnóstico de resíduos;
- construir intervalos de confiança e de predição para cenários específicos, com interpretação prática.

## Variável resposta:

Usaremos `flipper_length_mm` — o comprimento da nadadeira, em milímetros — como resposta. Queremos investigar e prever essa medida partir das demais informações disponíveis sobre o pinguim: espécie, ilha, medidas do bico, massa corporal, sexo e ano de coleta.

Pergunta formulada:

Entre pinguins semelhantes nas demais características consideradas, como o comprimento esperado da nadadeira varia com cada preditor, e quão bem o modelo prevê novos pinguins?

## 2. Metodologia

A análise estrutura-se em quatro etapas: (i) exploração dos dados, ausências e correlações; (ii) ajuste do modelo inicial e avaliação de multicolinearidade; (iii) seleção do modelo final via validação cruzada  $k$ -fold e testes de hipótese; e (iv) diagnóstico dos pressupostos dos resíduos, complementado pela construção de intervalos de confiança e de predição.

### 2.1 Modelo inicial de regressão linear múltipla

Seja  $y_i$  o comprimento da nadadeira, em milímetros, do  $i$ -ésimo pinguim. Após a retirada da variável `year`, avaliada exploratoriamente como pouco informativa para a resposta, e a remoção dos registros sem identificação de sexo, o modelo completo inicial foi definido com as variáveis morfológicas contínuas e as variáveis categóricas disponíveis:

$$y_i = \beta_0 + \beta_1 \text{tamBico}_i + \beta_2 \text{profundBico}_i + \beta_3 \text{massaCorp}_i + \beta_4 \text{chinstrap}_i + \beta_5 \text{gentoo}_i + \beta_6 \text{dream}_i + \beta_7 \text{torgersen}_i + \beta_8 \text{male}_i + \varepsilon_i.$$

Nesse modelo, `compBico`, `profundBico` e `massaCorp` representam, respectivamente, o comprimento do bico, a profundidade do bico e a massa corporal. As variáveis `chinstrap` e `gentoo` são indicadoras da espécie, tendo *Adelie* como categoria de referência; `dream` e `torgersen` são indicadoras da ilha, tendo *Biscoe* como referência; e `male` representa o sexo masculino, tendo *female* como referência. O termo  $\varepsilon_i$  representa o erro aleatório e segue as suposições usuais do MRLM: média nula, variância constante, independência e normalidade aproximada.

A multicolinearidade entre as variáveis explicativas foi avaliada pelo fator de inflação de variância,  $VIF_j = 1/(1-R_j^2)$ , em que  $R_j^2$  é o coeficiente de determinação da regressão de  $X_j$  sobre as demais explicativas; valores de  $VIF_j > 10$  foram tratados como indicativo de multicolinearidade severa. A seleção do modelo final foi conduzida pela comparação de subconjuntos de preditores por validação cruzada  $K$ -Fold ( $k = 5$ ), utilizando o RMSE médio como métrica principal de desempenho preditivo. O AIC e o BIC foram considerados como medidas auxiliares de ajuste e parcimônia, sem substituir a decisão baseada na validação cruzada e nos testes comparativos entre modelos.

## 2.2 Diagnóstico de Suposições

A validação do modelo vencedor ancorou-se na verificação gráfica e formal dos pressupostos clássicos dos resíduos:

- **Linearidade e Homocedasticidade:** Avaliadas pelo diagrama de resíduos versus valores ajustados e testadas pelo Teste de Breusch-Pagan ( $H_0$ : variância constante).
- **Normalidade dos Erros:** Inspeccionada pelo gráfico Q-Q Plot e submetida ao teste formal de Jarque-Bera ( $H_0$ : distribuição normal dos erros).
- **Independência dos Erros:** Verificada pelo Teste de Durbin-Watson ( $H_0$ : ausência de autocorrelação nos resíduos).

## 2.3 Critérios de Seleção e Validação Cruzada

Para prevenir o superajuste (*overfitting*) e priorizar a parcimônia, os modelos candidatos foram avaliados pelo Critério de Informação de Akaike (AIC), que equilibra qualidade de ajuste e quantidade de parâmetros.

A capacidade de generalização foi mensurada por Validação Cruzada  $K$ -Fold ( $k = 5$ ) com base no Erro Quadrático Médio de Predição (RMSE). Para comparar os modelos concorrentes neutralizando a dependência entre as dobras de treino e teste, aplicou-se o teste  $t$  pareado com a correção de variância de Nadeau-Bengio:

$$\sigma^2_{\text{corrigida}} = \left( \frac{1}{k} + \frac{n_{\text{teste}}}{n_{\text{treino}}} \right) s^2_{\text{diferença}}$$

## 3. Descrição da base

A base de dados Palmer Penguins possui  $n = 344$  espécimes registrados

Table 1: Dicionário de variáveis

| Variável          | Tipo       | Papel      | Definição                                      | Unidade    |
|-------------------|------------|------------|------------------------------------------------|------------|
| species           | Categórica | Preditor   | Espécie do pinguim (Adelie, Chinstrap, Gentoo) |            |
| island            | Categórica | Preditor   | Ilha de observação (Dream, Torgersen, Biscoe)  |            |
| bill_length_mm    | Numérica   | Preditor   | Comprimento do bico                            | milímetros |
| bill_depth_mm     | Numérica   | Preditor   | Profundidade do bico                           | milímetros |
| flipper_length_mm | Numérica   | Resposta   | Comprimento da nadadeira                       | milímetros |
| body_mass_g       | Numérica   | Preditor   | Massa corporal                                 | gramas     |
| sex               | Categórica | Preditor   | Sexo do pinguim (male, female)                 |            |
| year              | Inteira    | Descartada | Ano em que a observação foi registrada         |            |

## 4. Análise Exploratória

### 4.1 Distribuição das variáveis

Table 2: Amostra dos dados

| species | island    | bill_length_mm | bill_depth_mm | flipper_length_mm | body_mass_g | sex    | year |
|---------|-----------|----------------|---------------|-------------------|-------------|--------|------|
| Adelie  | Torgersen | 39.1           | 18.7          | 181               | 3750        | male   | 2007 |
| Adelie  | Torgersen | 39.5           | 17.4          | 186               | 3800        | female | 2007 |
| Adelie  | Torgersen | 40.3           | 18.0          | 195               | 3250        | female | 2007 |
| Adelie  | Torgersen | NA             | NA            | NA                | NA          | NA     | 2007 |
| Adelie  | Torgersen | 36.7           | 19.3          | 193               | 3450        | female | 2007 |

Figura 1: Contagem de Indivíduos pelas Variáveis Qualitativas





Figura 2: Distribuição das Variáveis Numéricas por Espécie



Os diagramas de caixa confirmam a consistência das distribuições morfométricas na amostra. As caixas interquartílicas evidenciam a amplitude do centro dos dados para cada medida física. Nota-se a semelhante distribuição, entre as espécies *Adelie* e *Chinstrap*, para características como massa corporal, tamanho da nadadeira e profundidade do bico, fato que pode ser explicado pela **convergência ecomorfológica e sobreposição parcial de nicho trófico entre ambas as espécies**, que compartilham hábitos de forrageamento de menor profundidade em relação aos *Gentoo*. Por outro lado, a espécie *Gentoo* se distingue acentuadamente por apresentar maior massa corporal e nadadeiras significativamente mais longas (gigantismo relativo dentro do gênero), porém acompanhadas por bicos proporcionalmente mais rasos (*bill depth*).

## 4.2 Tratamento de dados

**4.2.1 Variável Sexo** Percebe-se que, na Figura 1, possuímos uma parcela de espécimes que não possuem seu sexo identificado. Com isso, avaliaremos o nível de importância dessa variável a fim de tomar uma decisão quanto à remoção dos espécimes com informações faltantes ou à inclusão desses espécimes ao modelo.

Considerando as seguintes hipóteses:

$$H_0 : \mu_{\text{male}} = \mu_{\text{female}}$$


$$H_1 : \mu_{\text{male}} \neq \mu_{\text{female}}$$

Ao realizarmos um teste t de Student para a variável descrita, rejeitamos a hipótese nula de igualdade entre as médias, por termos obtido  $t = 4,801$  e  $p < 0,001$ . Há evidências suficientes que indicam uma associação entre o sexo e o tamanho da nadadeira.

Ao realizarmos a aplicação do Coeficiente de Cohen, demonstramos que a variável sexo possui alta relevância preditiva e explicativa em relação ao comprimento da nadadeira, o que inviabiliza a exclusão da coluna inteira do conjunto de dados.


A variável apresentou 11 registros ausentes (NaN), o que corresponde a aproximadamente 3,2% da base total. Na literatura de análise de dados, proporções de dados faltantes inferiores a 5% são frequentemente tratadas através da exclusão das observações, já que a perda de poder estatístico é negligenciável.

### 4.2.2 Variável Ano




A variável em questão, não contribui com a explicabilidade da variável resposta visto que, embora o gráfico revele uma sutil variação negativa na mediana do ano de 2007 e uma assimetria na distribuição dos anos subsequentes (com maior concentração de pontos entre o terceiro e quarto quartis), essas nuances visuais não justificam a utilização dessa variável no modelo. A concentração assimétrica na porção superior das caixas reflete, na verdade, uma distribuição bimodal causada pela sobreposição das diferentes espécies na amostra anual, especificamente a presença da espécie Gentoo, cujos espécimes possuem dimensões naturalmente maiores. Dado que essa variação milimétrica interanual não oferece ganho preditivo ou explicativo relevante em comparação com as variáveis biológicas principais (*Sexo* e *Espécie*), a desconsideração da variável temporal *Ano* não contribuirá para perda significativa de informação.


### 4.3 Avaliação de correlação entre variáveis



A Figura 4 apresenta a matriz de correlação de Pearson entre as variáveis numéricas contínuas. Observa-se uma forte correlação positiva entre o comprimento da nadadeira (`flipper_length_mm`) e a massa corporal (`body_mass_g`) ( $r = 0,87$ ), evidenciando que a massa é o principal preditor linear contínuo do tamanho do apêndice. O comprimento do bico (`bill_length_mm`) também exibe correlação positiva considerável ( $r = 0,65$ ) com a variável resposta. Em contrapartida, a profundidade do bico (`bill_depth_mm`) apresenta correlação negativa com a nadadeira ( $r = -0,58$ ), um comportamento aparente causado pela presença da espécie *Gentoo*, cujos indivíduos possuem nadadeiras longas e bicos finos.



Pela separação de espécies, fica clara a forte e positiva correlação entre a massa corporal do pinguim e o tamanho de sua nadadeira, isso para todas as três espécies avaliadas. Ademais, vê-se uma extensão da similaridade antes comprovada nos boxplots que as espécies *Adelie* e *Chinstrap* compartilham de características intrínsecas para tamanho da nadadeira e profundidade do bico



## 5. Seleção de Variáveis e Regressão dos modelos

A partir do modelo inicial apresentado na Seção 2.1, com todas as variáveis explicativas disponíveis (exceto os espécimes sem sexo identificado, tratados na Seção 4.2.1), construímos o Modelo Completo como ponto de partida para a seleção de variáveis:

$$y_i = \beta_0 + \beta_1 \text{tamBico}_i + \beta_2 \text{profundBico}_i + \beta_3 \text{massaCorp}_i + \beta_4 \text{chinstrap}_i + \beta_5 \text{gentoo}_i + \beta_6 \text{dream}_i + \beta_7 \text{torgersen}_i + \beta_8 \text{male}_i + \varepsilon_i.$$

em que *Chinstrap* e *Gentoo* são indicadoras da espécie (*Adelie* como referência), *Dream* e *Torgersen* são indicadoras da ilha (*Biscoe* como referência) e *male* é indicadora do sexo (*female* como referência). Antes de comparar subconjuntos de preditores por validação cruzada (Seção 5.1), avaliamos primeiro se a variável espécie — apontada na análise exploratória (Seções 4.1 e 4.3) como fortemente associada às demais medidas morfológicas — de fato acrescenta poder explicativo, comparando por ANOVA o Modelo Completo contra sua versão restrita sem espécie.

Table 3: Análise de Variância comparando o modelo restrito e o completo.

| Modelo             | GL Res. | RSS      | GL | Soma dos Quadrados | Estat. F | Valor-p |
|--------------------|---------|----------|----|--------------------|----------|---------|
| Modelo Sem Espécie | 326     | 10820.65 | NA | NA                 | NA       | NA      |
| Modelo Com Espécie | 324     | 8768.47  | 2  | 2052.18            | 37.91    | < 0,001 |

Para validar estatisticamente a inclusão da variável qualitativa correspondente à espécie do pinguim, realizou-se uma Análise de Variância (ANOVA) comparando um modelo restrito (sem a referida variável) e o modelo completo. O teste F indicou uma redução significativa na soma dos quadrados dos resíduos (RSS) no modelo completo. Com uma estatística  $F = 37.914$  e um valor de  $p < 0.001$ , rejeitamos a hipótese nula de que os dois modelos possuem a mesma capacidade explicativa. Conclui-se, portanto, que a característica biológica da espécie contribui de forma estatisticamente significativa para a predição do comprimento da nadadeira, justificando sua permanência na regressão final.

Table 4: Estimativas dos coeficientes do modelo vencedor.

| Variável             | Estimativa | Erro Padrão | Estatística t | Valor-p   |
|----------------------|------------|-------------|---------------|-----------|
| Intercepto           | 136.7308   | 5.1683      | 26.4558       | < 0,001   |
| Espécie: Chinstrap   | 1.4260     | 1.4420      | 0.9889        | 0,3234391 |
| Espécie: Gentoo      | 18.9123    | 2.2891      | 8.2618        | < 0,001   |
| Comprimento do Bico  | 0.4073     | 0.1235      | 3.2992        | 0,0010764 |
| Profundidade do Bico | 0.9194     | 0.3402      | 2.7024        | 0,0072433 |
| Massa Corporal       | 0.0056     | 0.0009      | 6.4517        | < 0,001   |

**5.1 Seleção do Modelo via Validação Cruzada Exaustiva** Para determinar a combinação ideal de variáveis preditoras, realizou-se preliminarmente uma busca exaustiva, pela combinação de variáveis à distintos modelos, avaliada por Validação Cruzada K-Fold ( $k = 5$ ). O modelo que minimizou o Erro Quadrático Médio (RMSE = 5.29 mm) foi composto pelas variáveis: `species`, `bill_length_mm`, `bill_depth_mm` e `body_mass_g`. Para garantir a robustez dessa escolha, os resíduos dos folds foram submetidos a um teste t pareado com correção de Nadeau-Bengio, o qual ajusta a variância estimada para compensar a dependência entre folds, buscando evitar a inflação de falsos positivos. O modelo selecionado demonstrou superioridade estatisticamente significativa ( $p = 0.02$ ) contra um modelo restrito apenas a variáveis contínuas, consolidando a importância de mesclar a morfologia do bico e da massa com a categorização da espécie. As variáveis `sex` e `island` foram descartadas por não apresentarem ganho preditivo significativo nesta configuração.

Table 5: Comparativo de Desempenho Preditivo entre Subconjuntos de Variáveis

| Modelo                  | Variáveis Preditores                              | RMSE Médio (K-Fold) |
|-------------------------|---------------------------------------------------|---------------------|
| Vencedor (Completo)     | Espécie, Bico (Comprimento e Profundidade), Massa | 5.29 mm             |
| Modelo A (Qualitativo)  | Espécie, Ilha, Sexo                               | 5.77 mm             |
| Modelo B (Quantitativo) | Bico (Comprimento e Profundidade), Massa          | 5.86 mm             |

### Diagnóstico de Multicolinearidade do Modelo Vencedor

Table 6: Fator de Inflação da Variância (VIF) do modelo vencedor.

| Variável                       | VIF    |
|--------------------------------|--------|
| <code>species_Chinstrap</code> | 4.115  |
| <code>species_Gentoo</code>    | 14.654 |
| <code>bill_length_mm</code>    | 5.534  |
| <code>bill_depth_mm</code>     | 5.449  |
| <code>body_mass_g</code>       | 5.894  |

A variável indicadora referente à espécie *Gentoo* apresenta  $VIF = 14,65$ , ultrapassando o limiar de severidade ( $VIF > 10$ ) definido na Seção 2.1, enquanto as demais variáveis permanecem em um patamar moderado ( $VIF$  entre 4 e 6). Esse resultado decorre da forte associação entre a espécie *Gentoo* e as variáveis `body_mass_g` e `bill_depth_mm`: indivíduos dessa espécie apresentam massa corporal média de 5.092g, cerca de 37% acima de *Adelie* (3.706g) e *Chinstrap* (3.733g), e profundidade de bico média de 15,0mm, sensivelmente menor que os cerca de 18,3–18,4mm observados nas outras duas espécies. Ainda assim, entre os subconjuntos avaliados na Seção 5.1, o modelo vencedor apresentou o menor RMSE médio via validação cruzada, e sua remoção da variável espécie (Modelo B) resultou em desempenho preditivo inferior. Optou-se, portanto, por manter a variável, reconhecendo que a colinearidade residual associada a *Gentoo* limita a precisão da estimativa isolada desse coeficiente, sem comprometer a capacidade preditiva geral do modelo.

Complementarmente, a comparação entre o modelo vencedor e o Modelo A (Qualitativo: espécie, ilha e sexo) não indicou diferença estatisticamente significativa de desempenho preditivo ( $p = 0,14$ ), e a comparação entre o Modelo A e o Modelo B (Quantitativo) também não foi significativa ( $p = 0,79$ ). Em conjunto, esses três testes sugerem que ilha e sexo carregam pouca informação preditiva adicional sobre o comprimento da nadadeira depois de considerar espécie e as medidas contínuas, reforçando a decisão de excluí-las do modelo final por parcimônia.

## 6. Análise de Resíduos




Table 7: Testes Formais de Diagnóstico dos Resíduos do Modelo Vencedor.

| Teste Diagnóstico | Premissa Avaliada         | Estatística | Valor-p   |
|-------------------|---------------------------|-------------|-----------|
| Breusch-Pagan     | Homocedasticidade         | 15.4721     | 0,0085247 |
| Jarque-Bera       | Normalidade               | 7.1135      | 0,0285313 |
| Durbin-Watson     | Independência (Autocorr.) | 1.7715      | 0,0149767 |

