



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Disciplina: Estatística Aplicada – Período: 2026.1

Professores: Profa. Dra. Amanda Gomes; Prof. Dr. Jerfson Bruno; Prof. Dr. Gilberto Matos

Modelagem da Relação entre Características Morfológicas de Pinguins

João Vítor Neves, Darlan Almeida, Emerson Sulpino

Departamento de Ciência da Computação - UFCG

Resumo Este trabalho aplica a metodologia de regressão linear múltipla (MRLM) ao conjunto de dados *Palmer Penguins*, proveniente do programa de Pesquisa Ecológica de Longo Prazo (LTER) na Antártica Ocidental, com o objetivo de modelar o comprimento da nadadeira de pinguins das espécies *Adelie*, *Chinstrap* e *Gentoo* a partir de variáveis morfológicas e categóricas. Realizou-se uma análise exploratória das distribuições, correlações e dados ausentes, seguida do ajuste de um modelo completo e da comparação de subconjuntos de preditores por validação cruzada *K-Fold*. O modelo selecionado, composto por espécie, comprimento do bico, profundidade do bico e massa corporal, apresentou o menor RMSE médio entre os candidatos avaliados. A comparação por teste *t* pareado com correção de Nadeau-Bengio reforçou a superioridade desse modelo em relação ao modelo apenas quantitativo, enquanto os diagnósticos indicaram boa capacidade explicativa, com presença de heterocedasticidade e leve afastamento da normalidade dos resíduos. Assim, o relatório preserva a seleção do modelo como uma decisão baseada no conjunto das evidências: desempenho preditivo, parcimônia, contribuição estatística da espécie e avaliação dos pressupostos.

Palavras-Chave: regressão linear múltipla, multicolinearidade, seleção de modelos, palmer penguins, análise exploratória, características morfométricas

1. Introdução

Este trabalho utiliza o conjunto de dados *Palmer Penguins*, coletado pelo programa de Pesquisa Ecológica de Longo Prazo (LTER) entre 2007 e 2009, para investigar quais características morfológicas e categóricas explicam o comprimento da nadadeira dos indivíduos amostrados. Diferentemente de uma descrição puramente correlacional, buscamos um modelo de regressão linear múltipla (MRLM) que permita interpretar efeitos parciais — isto é, o efeito de cada variável mantendo as demais constantes —, avaliar a adequação de suas suposições e quantificar a incerteza tanto para o valor médio esperado da resposta quanto para novas observações individuais.

Objetivos da análise

- caracterizar exploratoriamente as variáveis morfológicas e categóricas disponíveis;
- ajustar um modelo inicial com todas as variáveis explicativas e avaliar multicolinearidade;
- selecionar, entre modelos candidatos, aquele com melhor equilíbrio entre desempenho preditivo, parcimônia e colinearidade controlada dentro de limites aceitáveis;
- verificar as suposições do MRLM por meio de diagnóstico de resíduos;
- construir intervalos de confiança e de predição para cenários específicos, com interpretação prática.

Variável resposta:

Usaremos `flipper_length_mm` — o comprimento da nadadeira, em milímetros — como resposta. Queremos investigar e prever essa medida partir das demais informações disponíveis sobre o pinguim: espécie, ilha, medidas do bico, massa corporal, sexo e ano de coleta.

Pergunta formulada:

Entre pinguins semelhantes nas demais características consideradas, como o comprimento esperado da nadadeira varia com cada preditor, e quão bem o modelo prevê novos pinguins?

2. Metodologia

A análise estrutura-se em quatro etapas: (i) exploração dos dados, ausências e correlações; (ii) ajuste do modelo inicial e avaliação de multicolinearidade; (iii) seleção do modelo final via validação cruzada k -fold e testes de hipótese; e (iv) diagnóstico dos pressupostos dos resíduos, complementado pela construção de intervalos de confiança e de predição.

2.1 Modelo inicial de regressão linear múltipla

Seja y_i o comprimento da nadadeira, em milímetros, do i -ésimo pinguim. Após a retirada da variável `year`, avaliada exploratoriamente como pouco informativa para a resposta, e a remoção dos registros sem identificação de sexo, o modelo completo inicial foi definido com as variáveis morfológicas contínuas e as variáveis categóricas disponíveis:

$$y_i = \beta_0 + \beta_1 \text{tamBico}_i + \beta_2 \text{profundBico}_i + \beta_3 \text{massaCorp}_i + \beta_4 \text{chinstrap}_i + \beta_5 \text{gentoo}_i + \beta_6 \text{dream}_i + \beta_7 \text{torgersen}_i + \beta_8 \text{male}_i + \varepsilon_i.$$

Nesse modelo, `compBico`, `profundBico` e `massaCorp` representam, respectivamente, o comprimento do bico, a profundidade do bico e a massa corporal. As variáveis `chinstrap` e `gentoo` são indicadoras da espécie, tendo *Adelie* como categoria de referência; `dream` e `torgersen` são indicadoras da ilha, tendo *Biscoe* como referência; e `male` representa o sexo masculino, tendo *female* como referência. O termo ε_i representa o erro aleatório e segue as suposições usuais do MRLM: média nula, variância constante, independência e normalidade aproximada.

A multicolinearidade entre as variáveis explicativas foi avaliada pelo fator de inflação de variância, $VIF_j = 1/(1-R_j^2)$, em que R_j^2 é o coeficiente de determinação da regressão de X_j sobre as demais explicativas; valores de $VIF_j > 10$ foram tratados como indicativo de multicolinearidade severa. A seleção do modelo final foi conduzida pela comparação de subconjuntos de preditores por validação cruzada K -Fold ($k = 5$), utilizando o RMSE médio como métrica principal de desempenho preditivo. O AIC e o BIC foram considerados como medidas auxiliares de ajuste e parcimônia, sem substituir a decisão baseada na validação cruzada e nos testes comparativos entre modelos.

2.2 Diagnóstico de Suposições

A validação do modelo vencedor ancorou-se na verificação gráfica e formal dos pressupostos clássicos dos resíduos:

- **Linearidade e Homocedasticidade:** Avaliadas pelo diagrama de resíduos versus valores ajustados e testadas pelo Teste de Breusch-Pagan (H_0 : variância constante).
- **Normalidade dos Erros:** Inspeccionada pelo gráfico Q-Q Plot e submetida ao teste formal de Jarque-Bera (H_0 : distribuição normal dos erros).
- **Independência dos Erros:** Verificada pelo Teste de Durbin-Watson (H_0 : ausência de autocorrelação nos resíduos).

2.3 Critérios de Seleção e Validação Cruzada

Para prevenir o superajuste (*overfitting*) e priorizar a parcimônia, o Critério de Informação de Akaike (AIC) e o Critério Bayesiano de Schwarz (BIC) foram reportados como medidas complementares de ajuste do modelo final, embora a comparação formal entre os subconjuntos candidatos tenha sido conduzida por validação cruzada K -fold (RMSE) e teste t pareado com correção de Nadeau-Bengio, apresentados a seguir.

A capacidade de generalização foi mensurada por Validação Cruzada K -Fold ($k = 5$) com base no Erro Quadrático Médio de Predição (RMSE). Para comparar os modelos concorrentes neutralizando a dependência entre as dobras de treino e teste, aplicou-se o teste t pareado com a correção de variância de Nadeau-Bengio:

$$\sigma^2_{\text{corrigida}} = \left(\frac{1}{k} + \frac{n_{\text{teste}}}{n_{\text{treino}}} \right) s^2_{\text{diferença}}$$

3. Descrição da base

A base de dados Palmer Penguins possui $n = 344$ espécimes registrados

Table 1: Dicionário de variáveis

Variável	Tipo	Papel	Definição	Unidade
species	Categórica	Preditor	Espécie do pinguim (Adelie, Chinstrap, Gentoo)	
island	Categórica	Preditor	Ilha de observação (Dream, Torgersen, Biscoe)	
bill_length_mm	Numérica	Preditor	Comprimento do bico	milímetros
bill_depth_mm	Numérica	Preditor	Profundidade do bico	milímetros
flipper_length_mm	Numérica	Resposta	Comprimento da nadadeira	milímetros
body_mass_g	Numérica	Preditor	Massa corporal	gramas
sex	Categórica	Preditor	Sexo do pinguim (male, female)	
year	Inteira	Descartada	Ano em que a observação foi registrada	

4. Análise Exploratória

4.1 Distribuição das variáveis

Table 2: Amostra dos dados

species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	sex	year
Adelie	Torgersen	39.1	18.7	181	3750	male	2007
Adelie	Torgersen	39.5	17.4	186	3800	female	2007
Adelie	Torgersen	40.3	18.0	195	3250	female	2007
Adelie	Torgersen	NA	NA	NA	NA	NA	2007
Adelie	Torgersen	36.7	19.3	193	3450	female	2007

Figura 1: Contagem de Indivíduos pelas Variáveis Qualitativas





Figura 2: Distribuição das Variáveis Numéricas por Espécie



Os diagramas de caixa confirmam a consistência das distribuições morfométricas na amostra. As caixas interquartílicas evidenciam a amplitude do centro dos dados para cada medida física. Nota-se a semelhante distribuição, entre as espécies *Adelie* e *Chinstrap*, para características como massa corporal, tamanho da nadadeira e profundidade do bico, fato que pode ser explicado pela **convergência ecomorfológica e sobreposição parcial de nicho trófico entre ambas as espécies**, que compartilham hábitos de forrageamento de menor profundidade em relação aos *Gentoo*. Por outro lado, a espécie *Gentoo* se distingue acentuadamente por apresentar maior massa corporal e nadadeiras significativamente mais longas (gigantismo relativo dentro do gênero), porém acompanhadas por bicos proporcionalmente mais rasos (*bill depth*).

4.2 Tratamento de dados

4.2.1 Variável Sexo Percebe-se que, na Figura 1, possuímos uma parcela de espécimes que não possuem seu sexo identificado. Com isso, avaliaremos o nível de importância dessa variável a fim de tomar uma decisão quanto à remoção dos espécimes com informações faltantes ou à inclusão desses espécimes ao modelo.

Considerando as seguintes hipóteses:

$$H_0 : \mu_{\text{male}} = \mu_{\text{female}}$$


$$H_1 : \mu_{\text{male}} \neq \mu_{\text{female}}$$

Ao realizarmos um teste t de Student para a variável descrita, rejeitamos a hipótese nula de igualdade entre as médias, por termos obtido $t = 4,801$ e $p < 0,001$. Há evidências suficientes que indicam uma associação entre o sexo e o tamanho da nadadeira.

Ao realizarmos a aplicação do Coeficiente de Cohen, demonstramos que a variável sexo possui alta relevância preditiva e explicativa em relação ao comprimento da nadadeira, o que inviabiliza a exclusão da coluna inteira do conjunto de dados.


A variável apresentou 11 registros ausentes (NaN), o que corresponde a aproximadamente 3,2% da base total. Na literatura de análise de dados, proporções de dados faltantes inferiores a 5% são frequentemente tratadas através da exclusão das observações, já que a perda de poder estatístico é negligenciável.

4.2.2 Variável Ano




A variável em questão, não contribui com a explicabilidade da variável resposta visto que, embora o gráfico revele uma sutil variação negativa na mediana do ano de 2007 e uma assimetria na distribuição dos anos subsequentes (com maior concentração de pontos entre o terceiro e quarto quartis), essas nuances visuais não justificam a utilização dessa variável no modelo. A concentração assimétrica na porção superior das caixas reflete, na verdade, uma distribuição bimodal causada pela sobreposição das diferentes espécies na amostra anual, especificamente a presença da espécie Gentoo, cujos espécimes possuem dimensões naturalmente maiores. Dado que essa variação milimétrica interanual não oferece ganho preditivo ou explicativo relevante em comparação com as variáveis biológicas principais (*Sexo* e *Espécie*), a desconsideração da variável temporal *Ano* não contribuirá para perda significativa de informação.


4.3 Avaliação de correlação entre variáveis



A Figura 4 apresenta a matriz de correlação de Pearson entre as variáveis numéricas contínuas. Observa-se uma forte correlação positiva entre o comprimento da nadadeira (`flipper_length_mm`) e a massa corporal (`body_mass_g`) ($r = 0,87$), evidenciando que a massa é o principal preditor linear contínuo do tamanho do apêndice. O comprimento do bico (`bill_length_mm`) também exibe correlação positiva considerável ($r = 0,65$) com a variável resposta. Em contrapartida, a profundidade do bico (`bill_depth_mm`) apresenta correlação negativa com a nadadeira ($r = -0,58$), um comportamento aparente causado pela presença da espécie *Gentoo*, cujos indivíduos possuem nadadeiras longas e bicos finos.



Pela separação de espécies, fica clara a forte e positiva correlação entre a massa corporal do pinguim e o tamanho de sua nadadeira, isso para todas as três espécies avaliadas. Ademais, vê-se uma extensão da similaridade antes comprovada nos boxplots que as espécies *Adelie* e *Chinstrap* compartilham de características intrínsecas para tamanho da nadadeira e profundidade do bico



5. Seleção de Variáveis e Regressão dos modelos

A partir do modelo inicial apresentado na Seção 2.1, com todas as variáveis explicativas disponíveis (exceto os espécimes sem sexo identificado, tratados na Seção 4.2.1), construímos o Modelo Completo como ponto de partida para a seleção de variáveis:

$$y_i = \beta_0 + \beta_1 \text{tamBico}_i + \beta_2 \text{profundBico}_i + \beta_3 \text{massaCorp}_i + \beta_4 \text{chinstrap}_i + \beta_5 \text{gentoo}_i + \beta_6 \text{dream}_i + \beta_7 \text{torgersen}_i + \beta_8 \text{male}_i + \varepsilon_i.$$

em que *Chinstrap* e *Gentoo* são indicadoras da espécie (*Adelie* como referência), *Dream* e *Torgersen* são indicadoras da ilha (*Biscoe* como referência) e *male* é indicadora do sexo (*female* como referência). Antes de comparar subconjuntos de preditores por validação cruzada (Seção 5.1), avaliamos primeiro se a variável espécie — apontada na análise exploratória (Seções 4.1 e 4.3) como fortemente associada às demais medidas morfológicas — de fato acrescenta poder explicativo, comparando por ANOVA o Modelo Completo contra sua versão restrita sem espécie.

Table 3: Análise de Variância comparando o modelo restrito e o completo.

Modelo	GL Res.	RSS	GL	Soma dos Quadrados	Estat. F	Valor-p
Modelo Sem Espécie	326	10820.65	NA	NA	NA	NA
Modelo Com Espécie	324	8768.47	2	2052.18	37.91	< 0,001

Para validar estatisticamente a inclusão da variável qualitativa correspondente à espécie do pinguim, realizou-se uma Análise de Variância (ANOVA) comparando um modelo restrito (sem a referida variável) e o modelo completo. O teste F indicou uma redução significativa na soma dos quadrados dos resíduos (RSS) no modelo completo. Com uma estatística $F = 37.914$ e um valor de $p < 0.001$, rejeitamos a hipótese nula de que os dois modelos possuem a mesma capacidade explicativa. Conclui-se, portanto, que a característica biológica da espécie contribui de forma estatisticamente significativa para a predição do comprimento da nadadeira, justificando sua permanência na regressão final.

Table 4: Estimativas dos coeficientes do modelo vencedor.

Variável	Estimativa	Erro Padrão	Estatística t	Valor-p
Intercepto	136.7308	5.1683	26.4558	< 0,001
Espécie: Chinstrap	1.4260	1.4420	0.9889	0,3234391
Espécie: Gentoo	18.9123	2.2891	8.2618	< 0,001
Comprimento do Bico	0.4073	0.1235	3.2992	0,0010764
Profundidade do Bico	0.9194	0.3402	2.7024	0,0072433
Massa Corporal	0.0056	0.0009	6.4517	< 0,001

Table 5: Medidas globais de ajuste do modelo vencedor.

Medida	Valor
R^2 ajustado	0.861
AIC	2054.710
BIC	2081.370

O modelo vencedor apresentou R^2 ajustado de 0,861, indicando que aproximadamente 86,1% da variabilidade observada no comprimento da nadadeira é explicada pelas variáveis incluídas na regressão. Os valores de AIC (2054.71) e BIC (2081.37) são apresentados como medidas complementares de ajuste e parcimônia do modelo selecionado. Como esses critérios foram calculados apenas para o modelo final, eles não foram utilizados para comparar os modelos candidatos; a seleção foi baseada no menor RMSE obtido por validação cruzada.

5.1 Seleção do Modelo via Validação Cruzada Exaustiva Para determinar a combinação ideal de variáveis preditoras, realizou-se preliminarmente uma busca exaustiva, pela combinação de variáveis à distintos modelos, avaliada por Validação Cruzada K-Fold ($k = 5$). O modelo que minimizou o Erro Quadrático Médio (RMSE = 5.29 mm) foi composto pelas variáveis: species, bill_length_mm, bill_depth_mm e body_mass_g. Para garantir a robustez dessa escolha, os resíduos dos folds foram submetidos a um teste t pareado com correção de Nadeau-Bengio, o qual ajusta a variância estimada para compensar a dependência entre folds, buscando evitar a inflação de falsos positivos. O modelo selecionado demonstrou superioridade estatisticamente significativa ($p = 0.02$) contra um modelo restrito apenas a variáveis contínuas, consolidando a importância de mesclar a morfologia do bico e da massa com a categorização da espécie. As variáveis sex e island foram descartadas por não apresentarem ganho preditivo significativo nesta configuração.

Table 6: Comparativo de Desempenho Preditivo entre Subconjuntos de Variáveis

Modelo	Variáveis Preditores	RMSE Médio (K-Fold)
Vencedor (Completo)	Espécie, Bico (Comprimento e Profundidade), Massa	5.29 mm
Modelo A (Qualitativo)	Espécie, Ilha, Sexo	5.77 mm
Modelo B (Quantitativo)	Bico (Comprimento e Profundidade), Massa	5.86 mm

5.2 Diagnóstico de Multicolinearidade do Modelo Vencedor

Table 7: Fator de Inflação da Variância (VIF) do modelo vencedor.

Variável	VIF
species_Chinstrap	4.115
species_Gentoo	14.654

bill_length_mm	5.534
bill_depth_mm	5.449
body_mass_g	5.894

A variável indicadora referente à espécie *Gentoo* apresenta $VIF = 14,65$, ultrapassando o limiar de severidade ($VIF > 10$) definido na Seção 2.1, enquanto as demais variáveis permanecem em um patamar moderado (VIF entre 4 e 6). Esse resultado decorre da forte associação entre a espécie *Gentoo* e as variáveis `body_mass_g` e `bill_depth_mm`: indivíduos dessa espécie apresentam massa corporal média de 5.092g, cerca de 37% acima de *Adelie* (3.706g) e *Chinstrap* (3.733g), e profundidade de bico média de 15,0mm, sensivelmente menor que os cerca de 18,3–18,4mm observados nas outras duas espécies. Ainda assim, entre os subconjuntos avaliados na Seção 5.1, o modelo vencedor apresentou o menor RMSE médio via validação cruzada, e sua remoção da variável espécie (Modelo B) resultou em desempenho preditivo inferior. Optou-se, portanto, por manter a variável, reconhecendo que a colinearidade residual associada a *Gentoo* limita a precisão da estimativa isolada desse coeficiente, sem comprometer a capacidade preditiva geral do modelo.

Complementarmente, a comparação entre o modelo vencedor e o Modelo A (Qualitativo: espécie, ilha e sexo) não indicou diferença estatisticamente significativa de desempenho preditivo ($p = 0,14$), e a comparação entre o Modelo A e o Modelo B (Quantitativo) também não foi significativa ($p = 0,79$). Em conjunto, esses três testes sugerem que ilha e sexo carregam pouca informação preditiva adicional sobre o comprimento da nadadeira depois de considerar espécie e as medidas contínuas, reforçando a decisão de excluí-las do modelo final por parcimônia.

6. Análise de Resíduos





Table 8: Testes Formais de Diagnóstico dos Resíduos do Modelo Vencedor.

Teste Diagnóstico	Premissa Avaliada	Estatística	Valor-p
Breusch-Pagan	Homocedasticidade	15.4721	0,0085247
Jarque-Bera	Normalidade	7.1135	0,0285313
Durbin-Watson	Independência (Autocorr.)	1.7715	0,0149767



7. Previsão e Incerteza

Com o modelo vencedor, foram construídos três cenários representativos, correspondentes a um pinguim típico de cada espécie da base de dados. A Tabela 9 descreve as características morfológicas adotadas em cada cenário, e a Tabela 10 apresenta as estimativas do comprimento da nadadeira juntamente com seus respectivos intervalos de confiança (IC) e de predição (IP).

Table 9: Cenários hipotéticos utilizados na previsão.

Cenário	Espécie	Comp. Bico (mm)	Prof. Bico (mm)	Massa (g)
Pinguim A	Adelie	38.8	18.3	3700
Pinguim B	Chinstrap	48.8	18.4	3730
Pinguim C	Gentoo	47.5	15.0	5090

Table 10: Intervalos de confiança e de predição para o comprimento da nadadeira.

Cenário	Intervalo	Estimativa	Inferior	Superior
Pinguim A	IC 95% da média	190.02	189.16	190.87
Pinguim B	IC 95% da média	195.77	194.53	197.02
Pinguim C	IC 95% da média	217.20	216.25	218.14
Pinguim A	IP 95% individual	190.02	179.69	200.34
Pinguim B	IP 95% individual	195.77	185.41	206.14
Pinguim C	IP 95% individual	217.20	206.87	227.53

O intervalo de confiança (IC) captura a incerteza sobre o comprimento médio esperado de *todos* os pinguins com aquele conjunto de preditores; o intervalo de previsão (IP) captura a incerteza para *um único* pinguim

novo, incorporando também a variação residual do modelo — por isso é sempre mais amplo, e é o apropriado para estimar um indivíduo específico. Essa diferença aparece claramente nos três cenários: o IP é de 4 a 5 vezes mais largo que o IC correspondente (por exemplo, no Pinguim A, 11,71mm de amplitude contra apenas 1,71mm), refletindo que o IC responde apenas pela incerteza da média, enquanto o IP soma a ela a variabilidade individual não explicada pelo modelo.

O IC do Pinguim A (*Adelie*) é o mais estreito dos três (189,16 a 190,87mm), consequência do grande número de indivíduos dessa espécie na amostra ($n = 146$ após o tratamento da Seção 4.2.1). Além disso, os três cenários não se sobrepõem em nenhum dos dois tipos de intervalo, reforçando numericamente o que já havíamos observado nos boxplots da Seção 4.1 e no gráfico de resíduos por espécie da Seção 6: a espécie mantém forte poder discriminativo sobre o comprimento da nadadeira mesmo depois de controladas as medidas do bico e a massa corporal.